

Construye | Tests, validación de datos y seguridad básicos integrados al repositorio

Actualizado el 4 de noviembre de 2026

Iván Plata Garnica

Axel Fernando Rábago Díaz

Mónica María Ramírez Mejía

TC5061 Operaciones de aprendizaje automático · Grupo 10 · Equipo 46

01 de noviembre de 2026

Link al repositorio en GitHub: https://github.com/iplatamx/TC5061-Proyecto-Equipo46/tree/main

Resumen ejecutivo

Nombre del entregable: TC5061-Proyecto-Equipo46 | Repositorio: rama main

El informe reúne las pruebas automatizadas, la validación de datos con DeepChecks y la revisión básica de seguridad del repositorio MiBici. Las instrucciones permiten reproducir los chequeos y los anexos contienen capturas de las ejecuciones reportadas.

1. Pruebas unitarias y reproducibilidad con PyTest

Responsable: Axel Fernando Rábago Díaz. Se probaron funciones de preparación de datos, ingeniería de características, particiones temporales y reproducibilidad, cubriendo casos normales, límite e inválidos. Las pruebas usan datos controlados; no necesitan MLflow ni volver a ingerir los datos históricos.

1.1 Organización y ejecución

Las pruebas se encuentran en `tests/` y la configuración en `pytest.ini`:

```
python -m pytest tests/ -v
```

1.2 Pruebas implementadas

Archivo	Casos	Cobertura principal
test_dataset.py	6	Rangos de meses, limpieza de nombres, duplicados, datos personales, coordenadas y columnas obligatorias.
test_features.py	9	Objetivo de hora siguiente, validaciones de riesgo, viajes vacíos y perfiles de estaciones.
test_splits.py	4	Orden cronológico, fuga temporal y rechazo de periodos cortos.
test_reproducibility.py	2	Predicciones y métrica de KMeans con la misma semilla; validación de la semilla.
Total	21	21 aprobadas, 0 fallidas.

1.3 Reproducibilidad y resultados

La prueba entrena KMeans dos veces con datos sintéticos, la misma configuración y semilla, y compara las predicciones y la métrica. El entorno reportado fue Windows, Python 3.11.9 y pytest 9.2.0. La terminal informó `21 passed, 2 warnings in 9.38s`; la prueba de reproducibilidad, por separado, obtuvo `2 passed in 1.61s`. Las advertencias fueron avisos de obsolescencia de Typer y no causaron fallas. El 100% se refiere a los casos ejecutados, no a cobertura del código. Esta prueba no reproduce todo el pipeline ni los experimentos de MLflow. Véase el Anexo A.

2. Validación de datos con DeepChecks

Responsable: Ivan Plata Garnica. Se integraron chequeos de integridad y calidad de datos en P1, P2 y P3 para identificar valores faltantes o inválidos, tipos mezclados, duplicados, muestras atípicas, diferencias de distribución y posibles fugas temporales, cuando aplica.

2.1 Implementación

La lógica se encuentra en `mibici/modeling/data_validation.py`. Para P1 y P2, `validate_panel_splits` corre data_integrity en train, validation y test; después compara train/validation y train/test con train_test_validation. También verifica que las particiones no estén vacías, que tengan columnas requeridas y que las claves estación-hora sean válidas y únicas.

Para P3, `validate_station_profiles` revisa con data_integrity los perfiles y metadatos de estaciones. El flujo P3 no usa particiones train/test, por lo que no aplica comparación de drift entre ellas. Las dependencias específicas están fijadas en `requirements-deepchecks.txt`.

2.2 Comandos y reportes

Desde la raíz del repositorio, con Python 3.11, dependencias del proyecto y datos procesados disponibles:

```
.\.venv311\Scripts\python.exe -m pip install -r .\requirements-deepchecks.txt
.\.venv311\Scripts\python.exe -m mibici.modeling.train
.\.venv311\Scripts\python.exe -m mibici.modeling.train_p2
.\.venv311\Scripts\python.exe -m mibici.modeling.train_p3
```

Pipeline	Reportes HTML generados
P1	5: train, validation, test integrity; train/validation y train/test.
P2	5: train, validation, test integrity; train/validation y train/test.
P3	2: integridad de perfiles y metadatos.

Se generaron 12 reportes en `reports/deepchecks/`. Por su tamaño se excluyen de Git y se regeneran localmente; las capturas de cada pipeline están en el Anexo C.

2.3 Resultados de validación

Los tres pipelines terminaron y registraron sus ejecuciones en MLflow. Las métricas siguientes describen los modelos, no son puntuaciones de DeepChecks:

Pipeline	Resultado del entrenamiento
P1	MAE de prueba: 1.4756.
P2	F1 de prueba: 0.0000.
P3	K=3; Silhouette 0.4506; Calinski-Harabasz 263.9313.

Alcance	Hallazgos de DeepChecks
Comunes	Tipos mezclados pasaron y el chequeo de duplicados reportó 0%. No se detectó fuga temporal ni de índices. Mixed Nulls pasó: no encontró representaciones mixtas de nulos; esto no prueba que todas las columnas estén libres de faltantes.
P1	capacity y risk_threshold fueron constantes; hubo pares de variables con correlación >0.9. Train/validation tuvo 5.21% de muestras repetidas (umbral 5%). Multivariate Drift train/test: 0.31 (umbral 0.25); solapamiento train/test: 1.25%.
P2	target_time tuvo Predictive Power Score 0.04 frente al umbral 0. Se reportaron etiquetas conflictivas: 0.008% en validation y 0.002% en test. Solapamiento: 8.32% train/validation y 4.41% train/test. Multivariate Drift: 0.24 y 0.30, respectivamente (umbral 0.25).
P3	18 de 337 variables de perfiles fueron constantes; active y coords_valid fueron constantes en metadatos. También hubo pares de variables de perfil con correlación >0.9.

Las condiciones señaladas requieren interpretación; algunas constantes o correlaciones pueden ser patrones esperados. La ejecución exitosa confirma que se generaron informes, no certifica que el dataset esté libre de problemas.

3. Revisión de seguridad del repositorio

Responsable: Mónica María Ramírez Mejía. Se revisaron archivos sensibles, variables de entorno, posibles credenciales, código y dependencias con Bandit y pip-audit.

3.1 Credenciales, variables de entorno y .gitignore

Chequeo	Resultado
Archivos sensibles	Las rutas consultadas para .env, datos, MLflow y modelos están excluidas por .gitignore.
Variables de entorno	MLFLOW_TRACKING_URI; no es una credencial. .env.example no contiene secretos.
Búsqueda de credenciales	0 coincidencias en los patrones y tipos de archivo consultados; .env no aparece en Git ni en su historial.
Bandit	15 hallazgos de severidad baja; 0 medios y 0 altos.
pip-audit	53 vulnerabilidades reportadas en 4 dependencias directas.

Comandos de revisión

```
git check-ignore -v .env mlflow.db mlruns data/raw/ejemplo.csv models/modelo.pkl
git check-ignore -v mlruns/ mlartifacts/
git check-ignore -v .venv311/ reports/deepchecks/
git grep -n -i -E '(password|passwd|secret|api[_-]?key|token)\s*[:=]' -- '*.py' '*.md' '*.yaml' '*.toml' '*.json'
git ls-files -- .env
git log --all --oneline -- .env
```

La regla `.venv311/` y la exclusión de los reportes HTML locales de DeepChecks se añadieron el 4 de noviembre de 2026 y se verificaron con `git check-ignore -v`. Las capturas originales de seguridad se conservan en el Anexo B; las nuevas reglas se documentan aquí.

3.2 Manejo de información sensible

`mibici/config.py` carga el archivo local `.env` con `load_dotenv()`. Los scripts de modelado leen `MLFLOW_TRACKING_URI` con `os.getenv` y usan valores por defecto locales. La búsqueda de secretos se limita a patrones y archivos indicados; no constituye una garantía absoluta de ausencia de credenciales.

3.3 Análisis de código con Bandit

```
python -m bandit -r mibici
python -m bandit -r mibici -f txt -o reports/security/bandit.txt
```

Bandit 1.9.4 revisó 2,475 líneas de `mibici/`: 15 hallazgos de severidad baja, 0 medios y 0 altos. Están en cinco archivos de `mibici/modeling/` y corresponden a llamadas con argumentos fijos a `git rev-parse HEAD`. No se usa `shell=True` ni entradas del usuario; el equipo los clasifica como riesgo bajo.

Código	Descripción	Cantidad
B404	Importación de subprocess.	5
B603	Llamadas subprocess sin shell=True.	5
B607	Ejecución de git por nombre parcial.	5

3.4 Auditoría de dependencias con pip-audit

```
python -m pip_audit -r requirements.txt --no-deps --disable-pip -o reports/security/pip_audit.txt
```

La ejecución del 1 de noviembre de 2026 reportó 53 vulnerabilidades conocidas en cuatro paquetes:

Paquete	Versión	Avisos
mlflow	3.6.0	47
pyarrow	22.0.0	2
requests	2.32.5	2
python-dotenv	1.2.1	2

La auditoría se ejecutó con `--no-deps` y cubre los paquetes directos fijados en `requirements.txt`, no las dependencias indirectas. No se actualizaron versiones; cualquier cambio requiere volver a validar los experimentos y el registro de modelos. Los reportes completos se encuentran en `reports/security/`; las capturas están en el Anexo B.

Integración y entrega

El entregable TC5061-Proyecto-Equipo46 se consolida en main. Las contribuciones fueron integradas mediante PR #6 (PyTest, Axel), #9 (DeepChecks, Ivan), #5 (seguridad, Mónica) y #10 (documentación).

Uso de IA: Claude se usó como apoyo para estructurar comandos y redactar; las ejecuciones y capturas corresponden al equipo.

Referencias: pytest, docs.pytest.org; DeepChecks, docs.deepchecks.com; Bandit, bandit.readthedocs.io; pip-audit, pypi.org/project/pip-audit; Git, git-scm.com/docs/git-check-ignore.

Anexo A. Capturas de PyTest

Capturas de Axel Fernando Rábago Díaz, tomadas de docs/evidencias_semana7/ del repositorio.

```
061-Proyecto-Equipo46\.venv\Scripts\Activate.ps1)
(.venv) PS C:\Users\axelr\Documents\MaestriaIA\TC5061-Proyecto-Equipo46> python -m pytest tests/ -v
============================= test session starts ==============================
platform win32 -- Python 3.11.9, pytest-9.2.0, pluggy-1.7.0 -- C:\Users\axelr\Documents\MaestriaIA\TC5061-Proyecto-Equipo46\.venv\Scripts\python.exe
cachedir: .pytest_cache
rootdir: C:\Users\axelr\Documents\MaestriaIA\TC5061-Proyecto-Equipo46
configfile: pytest.ini
plugins: anyio-4.15.1
collected 21 items

tests/test_dataset.py::test_month_range_cruza_cambio_de_anio PASSED      [  4%]
tests/test_dataset.py::test_clean_name_normaliza_acentos_y_espacios PASSED [  9%]
tests/test_dataset.py::test_normalize_trips_limpia_duplicados_y_elimina_dato_personal PASSED [ 14%]
tests/test_dataset.py::test_normalize_trips_rechaza_columnas_obligatorias_faltantes PASSED [ 19%]
tests/test_dataset.py::test_normalize_stations_conserva_estacion_con_coordenadas_invalidas PASSED [ 23%]
tests/test_dataset.py::test_normalize_stations_rechaza_columnas_obligatorias_faltantes PASSED [ 28%]
tests/test_features.py::test_make_hourly_panel_objetivo_es_la_hora_siguiente PASSED [ 33%]
tests/test_features.py::test_make_hourly_panel_rechaza_riesgo_fuera_de_rango[0] PASSED [ 38%]
tests/test_features.py::test_make_hourly_panel_rechaza_riesgo_fuera_de_rango[-0.1] PASSED [ 42%]
tests/test_features.py::test_make_hourly_panel_rechaza_riesgo_fuera_de_rango[1.1] PASSED [ 47%]
tests/test_features.py::test_make_hourly_panel_rechaza_viajes_vacios PASSED [ 52%]
tests/test_features.py::test_make_hourly_panel_rechaza_columnas_faltantes PASSED [ 57%]
tests/test_features.py::test_build_station_profiles_genera_matriz_de_7_dias_por_24_horas PASSED [ 61%]
tests/test_features.py::test_build_station_profiles_excluye_estaciones_inactivas PASSED [ 66%]
tests/test_features.py::test_build_station_profiles_falla_si_no_hay_estaciones_validas PASSED [ 71%]
tests/test_reproducibility.py::test_p3_misma_semilla_mismas_predicciones_y_metrica PASSED [ 76%]
tests/test_reproducibility.py::test_semilla_del_proyecto_es_entera PASSED [ 80%]
tests/test_splits.py::test_split_mantiene_orden_y_evitar_fuga_temporal[chronological_split0] PASSED [ 85%]
tests/test_splits.py::test_split_mantiene_orden_y_evitar_fuga_temporal[chronological_split1] PASSED [ 90%]
tests/test_splits.py::test_split_rechaza_periodo_demasiado_corto[chronological_split0] PASSED [ 95%]
tests/test_splits.py::test_split_rechaza_periodo_demasiado_corto[chronological_split1] PASSED [100%]
```

Figura A1. Ejecución de las 21 pruebas unitarias con PyTest.

```
============================== 21 passed, 2 warnings in 9.38s ==============================
(.venv) PS C:\Users\axelr\Documents\MaestriaIA\TC5061-Proyecto-Equipo46> python -m pytest tests/ -q
.....................                                                    [100%]
=============================== warnings summary ===============================
.venv\Lib\site-packages\typer\__init__.py:24
  C:\Users\axelr\Documents\MaestriaIA\TC5061-Proyecto-Equipo46\.venv\Lib\site-packages\typer\__init__.py:24: DeprecationWarning: 'click.utils.get_binary_stream' is deprecated a
nd will be removed in Click 9.0.
    from click.utils import get_binary_stream as get_binary_stream

.venv\Lib\site-packages\typer\__init__.py:25
  C:\Users\axelr\Documents\MaestriaIA\TC5061-Proyecto-Equipo46\.venv\Lib\site-packages\typer\__init__.py:25: DeprecationWarning: 'click.utils.get_text_stream' is deprecated and
 will be removed in Click 9.0.
    from click.utils import get_text_stream as get_text_stream

-- Docs: https://docs.pytest.org/en/stable/how-to/capture-warnings.html
21 passed, 2 warnings in 2.86s
```

Figura A2. Resumen de resultados de PyTest.

```
(.venv) PS C:\Users\axelr\Documents\MaestriaIA\TC5061-Proyecto-Equipo46> python -m pytest tests/test_reproducibility.py -v
============================= test session starts ==============================
platform win32 -- Python 3.11.9, pytest-9.2.0, pluggy-1.7.0 -- C:\Users\axelr\Documents\MaestriaIA\TC5061-Proyecto-Equipo46\.venv\Scripts\python.exe
cachedir: .pytest_cache
rootdir: C:\Users\axelr\Documents\MaestriaIA\TC5061-Proyecto-Equipo46
configfile: pytest.ini
plugins: anyio-4.15.1
collected 2 items

tests/test_reproducibility.py::test_p3_misma_semilla_mismas_predicciones_y_metrica PASSED [ 50%]
tests/test_reproducibility.py::test_semilla_del_proyecto_es_entera PASSED [100%]

============================== 2 passed in 1.61s ===============================
```

Figura A3. Pruebas de reproducibilidad de KMeans (P3).

Anexo B. Capturas de seguridad

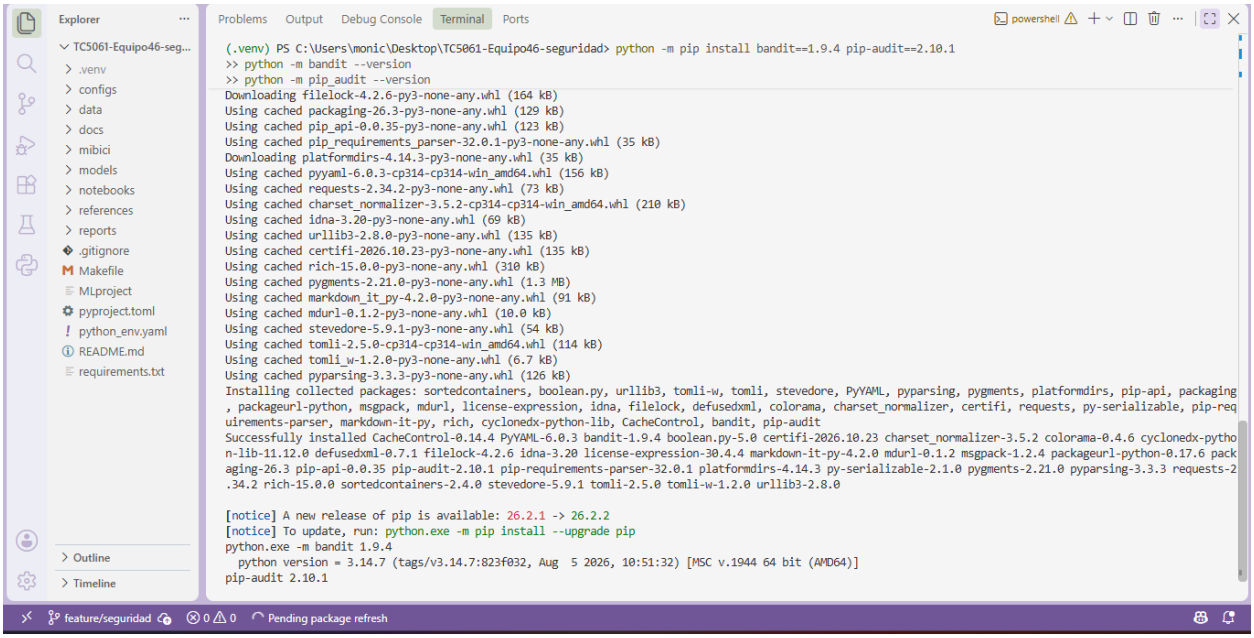


Figura B1. Instalación y versiones de bandit 1.9.4 y pip-audit 2.10.1.

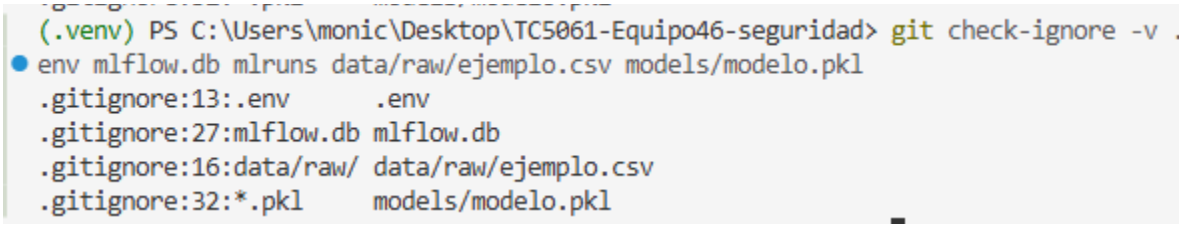


*Figura B2. git check-ignore: .env, mlflow.db, data/raw/ y *.pkl ignorados.*

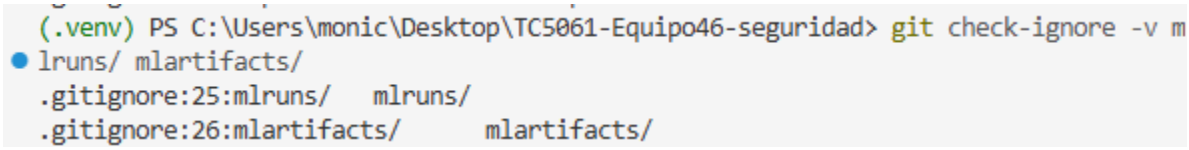


Figura B3. git check-ignore: mlruns/ y mlartifacts/ ignorados.

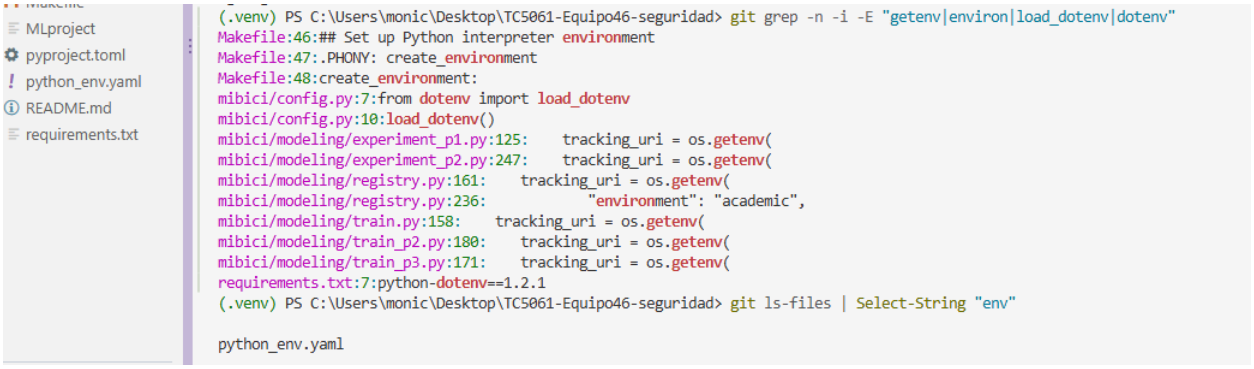


Figura B4. Variables de entorno (getenv y load_dotenv) y archivos con «env» en el nombre.

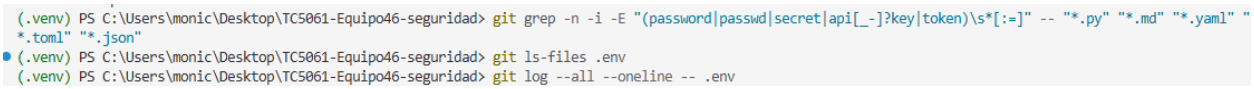


Figura B5. Búsqueda de credenciales y de .env: resultados vacíos.

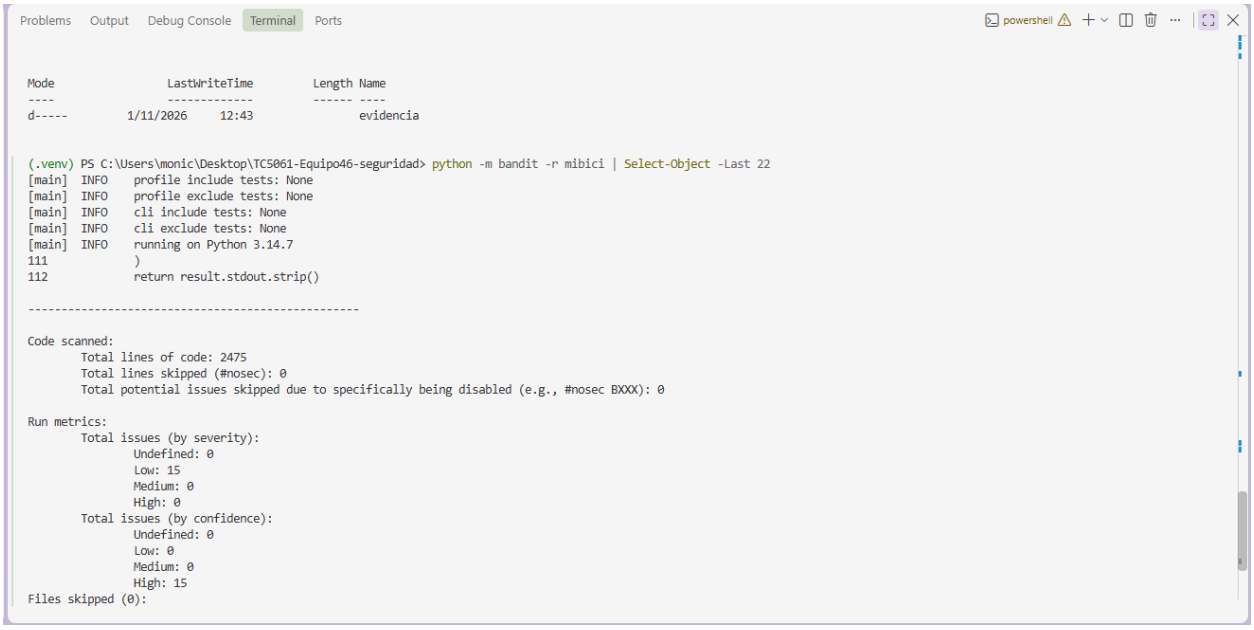


Figura B6. Resumen de bandit: 15 hallazgos de severidad baja.

```
security/bandit.txt\monic\Desktop\TC5061-Equipo46-seguridad>
[main]  INFO    cli include tests: None
[main]  INFO    cli exclude tests: None
[main]  INFO    running on Python 3.14.7
[text]  INFO    Text output written to file: reports/security/bandit.txt
(.venv) PS C:\Users\monic\Desktop\TC5061-Equipo46-seguridad> Select-String -Path reports/security/bandit.t
xt -Pattern "Issue: \[(B\d+:\w+)\]" | ForEach-Object { $_.Matches[0].Groups[1].Value } | Group-Object | Se
lect-Object Name, Count

Name                                   Count
----                                   -----
B404:blacklist                             5
B607:start_process_with_partial_path       5
B603:subprocess_without_shell_equals_true  5


(.venv) PS C:\Users\monic\Desktop\TC5061-Equipo46-seguridad> Select-String -Path reports/security/bandit.t
xt -Pattern "Location: (\S+):" | ForEach-Object { $_.Matches[0].Groups[1].Value } | Group-Object | Select-
Object Name, Count

Name                                 Count
----                                 -----
mibici\modeling\experiment_p1.py:13      1
mibici\modeling\experiment_p1.py:79      2
mibici\modeling\experiment_p2.py:20      1
mibici\modeling\experiment_p2.py:114     2
mibici\modeling\train.py:7               1
mibici\modeling\train.py:101             2
mibici\modeling\train_p2.py:7            1
mibici\modeling\train_p2.py:114          2
mibici\modeling\train_p3.py:17           1
mibici\modeling\train_p3.py:105          2
```

Figura B7. Hallazgos de bandit por tipo y por archivo y línea.

```
(.venv) PS C:\Users\monic\Desktop\TC5061-Equipo46-seguridad> python -m pip_audit -r requirements.txt --no-deps --disable-pip -o reports/security/pip_audit.txt
WARNING:pip_audit._cli:--no-deps is supported, but users are encouraged to fully hash their pinned dependencies
WARNING:pip_audit._cli:Consider using a tool like `pip-compile`: https://pip-tools.readthedocs.io/en/latest/#using-hashes
Found 53 known vulnerabilities in 4 packages
```

Figura B8. pip-audit: 53 vulnerabilidades en 4 paquetes.

```
(.venv) PS C:\Users\monic\Desktop\TC5061-Equipo46-seguridad> (Get-Content reports/security/pip_audit.txt |
 Select-Object -Skip 2) | ForEach-Object { $p = $_ -split '\s+'; "$($p[0]) $($p[1])" } | Group-Object | Se
lect-Object Name, Count

Name                                                                Count
----                                                                -----
pyarrow 22.0.0                2
requests 2.32.5              2
python-dotenv 1.2.1     2
mlflow 3.6.0                  47
```

Figura B9. Vulnerabilidades de pip-audit por paquete.

```
(.venv) PS C:\Users\monic\Desktop\TC5061-Equipo46-seguridad> git status --short
 M README.md
?? .env.example
?? docs/evidencia/
?? reports/security/
```

Figura B10. git status --short antes de los commits.

```
(.venv) PS C:\Users\monic\Desktop\TC5061-Equipo46-seguridad> git log --oneline -4
66e5719 (HEAD -> feature/seguridad) Documenta los chequeos de seguridad con evidencias en el README
98f8f03 Agrega reportes de bandit y pip-audit
2060a8f Agrega .env.example con la variable MLFLOW_TRACKING_URI
b00c369 (origin/main, main) Merge pull request #3 from MonicaRamirez-98/patch-1
(.venv) PS C:\Users\monic\Desktop\TC5061-Equipo46-seguridad> git status
On branch feature/seguridad
nothing to commit, working tree clean
```

Figura B11. Los tres commits de feature/seguridad.

```
(.venv) PS C:\Users\monic\Desktop\TC5061-Equipo46-seguridad> git push -u origin feature/seguridad
Enumerating objects: 26, done.
Counting objects: 100% (26/26), done.
Delta compression using up to 12 threads
Compressing objects: 100% (22/22), done.
Writing objects: 100% (22/22), 316.63 KiB | 7.54 MiB/s, done.
Total 22 (delta 5), reused 0 (delta 0), pack-reused 0 (from 0)
remote: Resolving deltas: 100% (5/5), completed with 3 local objects.
remote:
remote: Create a pull request for 'feature/seguridad' on GitHub by visiting:
remote:      https://github.com/iplatamx/TC5061-Proyecto-Equipo46/pull/new/feature/seguridad
remote:
To https://github.com/iplatamx/TC5061-Proyecto-Equipo46.git
 * [new branch]      feature/seguridad -> feature/seguridad
branch 'feature/seguridad' set up to track 'origin/feature/seguridad'.
```

Figura B12. Publicación de feature/seguridad en GitHub.

Anexo C. Evidencias de DeepChecks

Este anexo reúne tres capturas, una por pipeline: P1, P2 y P3.

Figura C.1. Ejecución de DeepChecks para P1

Captura de la ejecución del pipeline, la suite de DeepChecks y el mensaje final de registro.

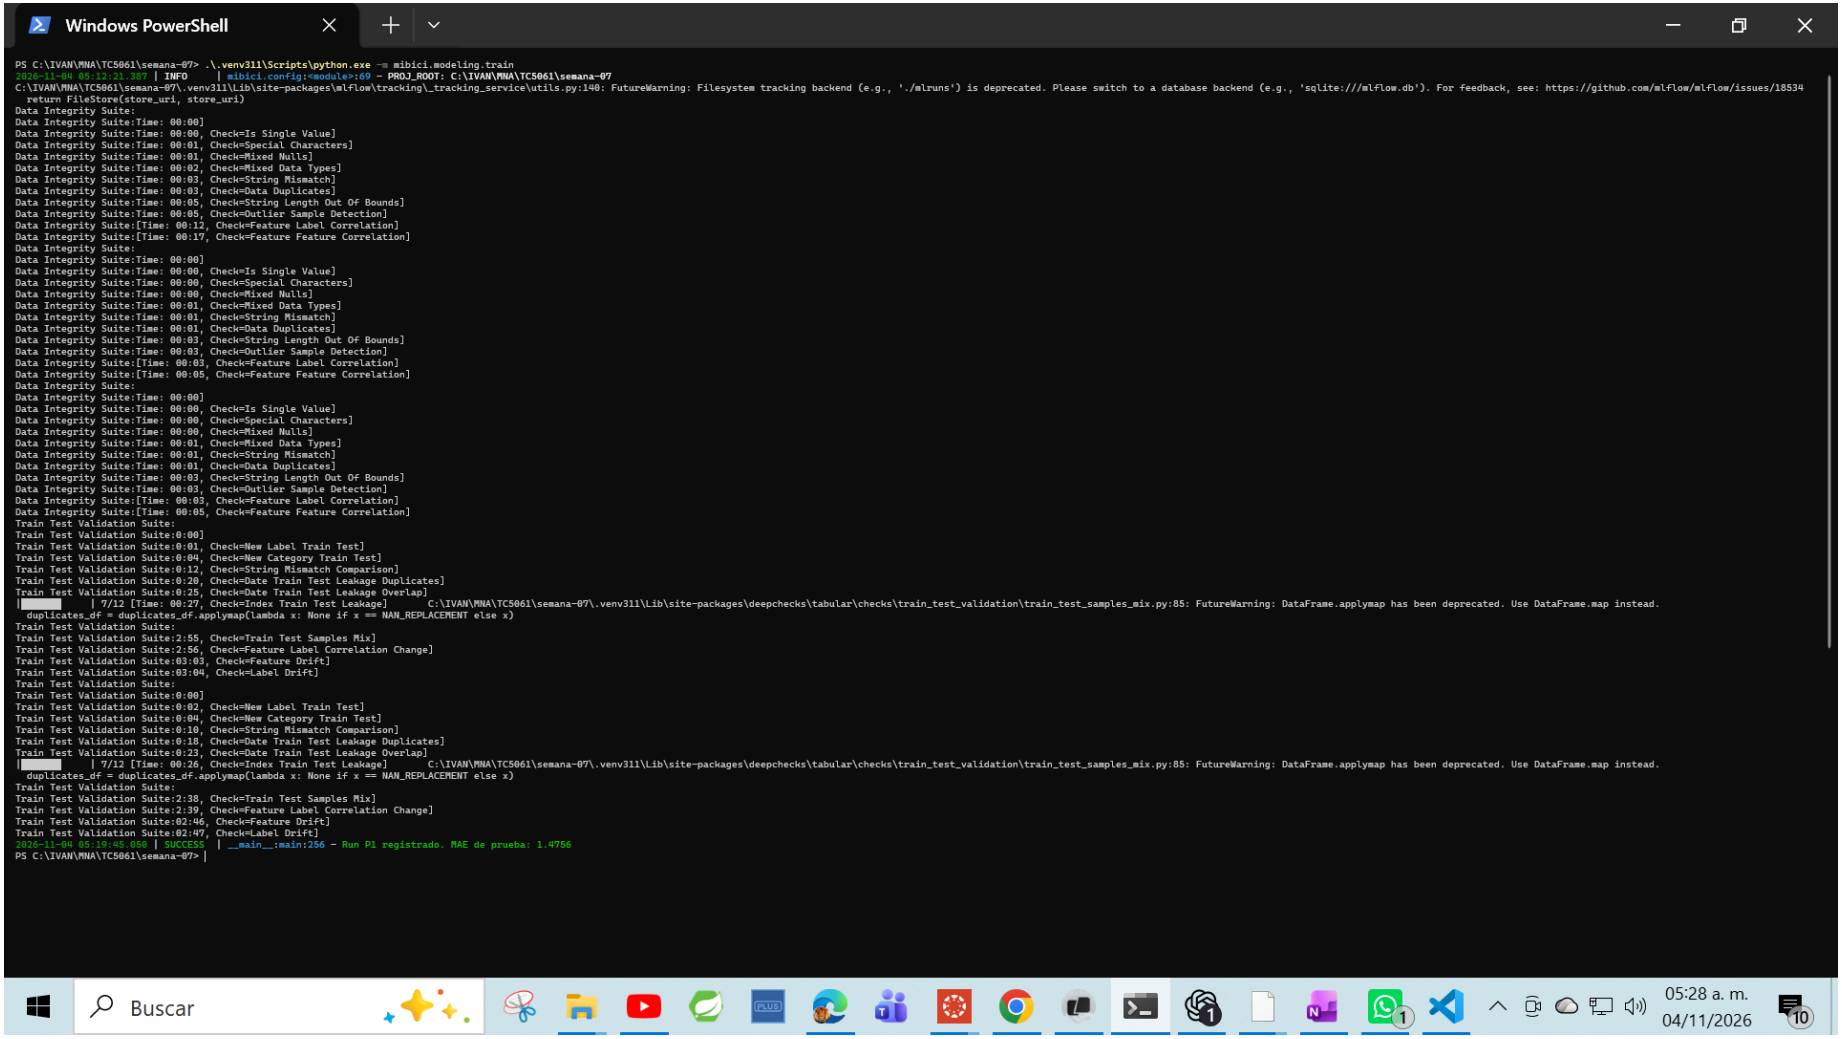


Figura C.2. Ejecución de DeepChecks para P2

Captura de la ejecución del pipeline, la suite de DeepChecks y el mensaje final de registro.

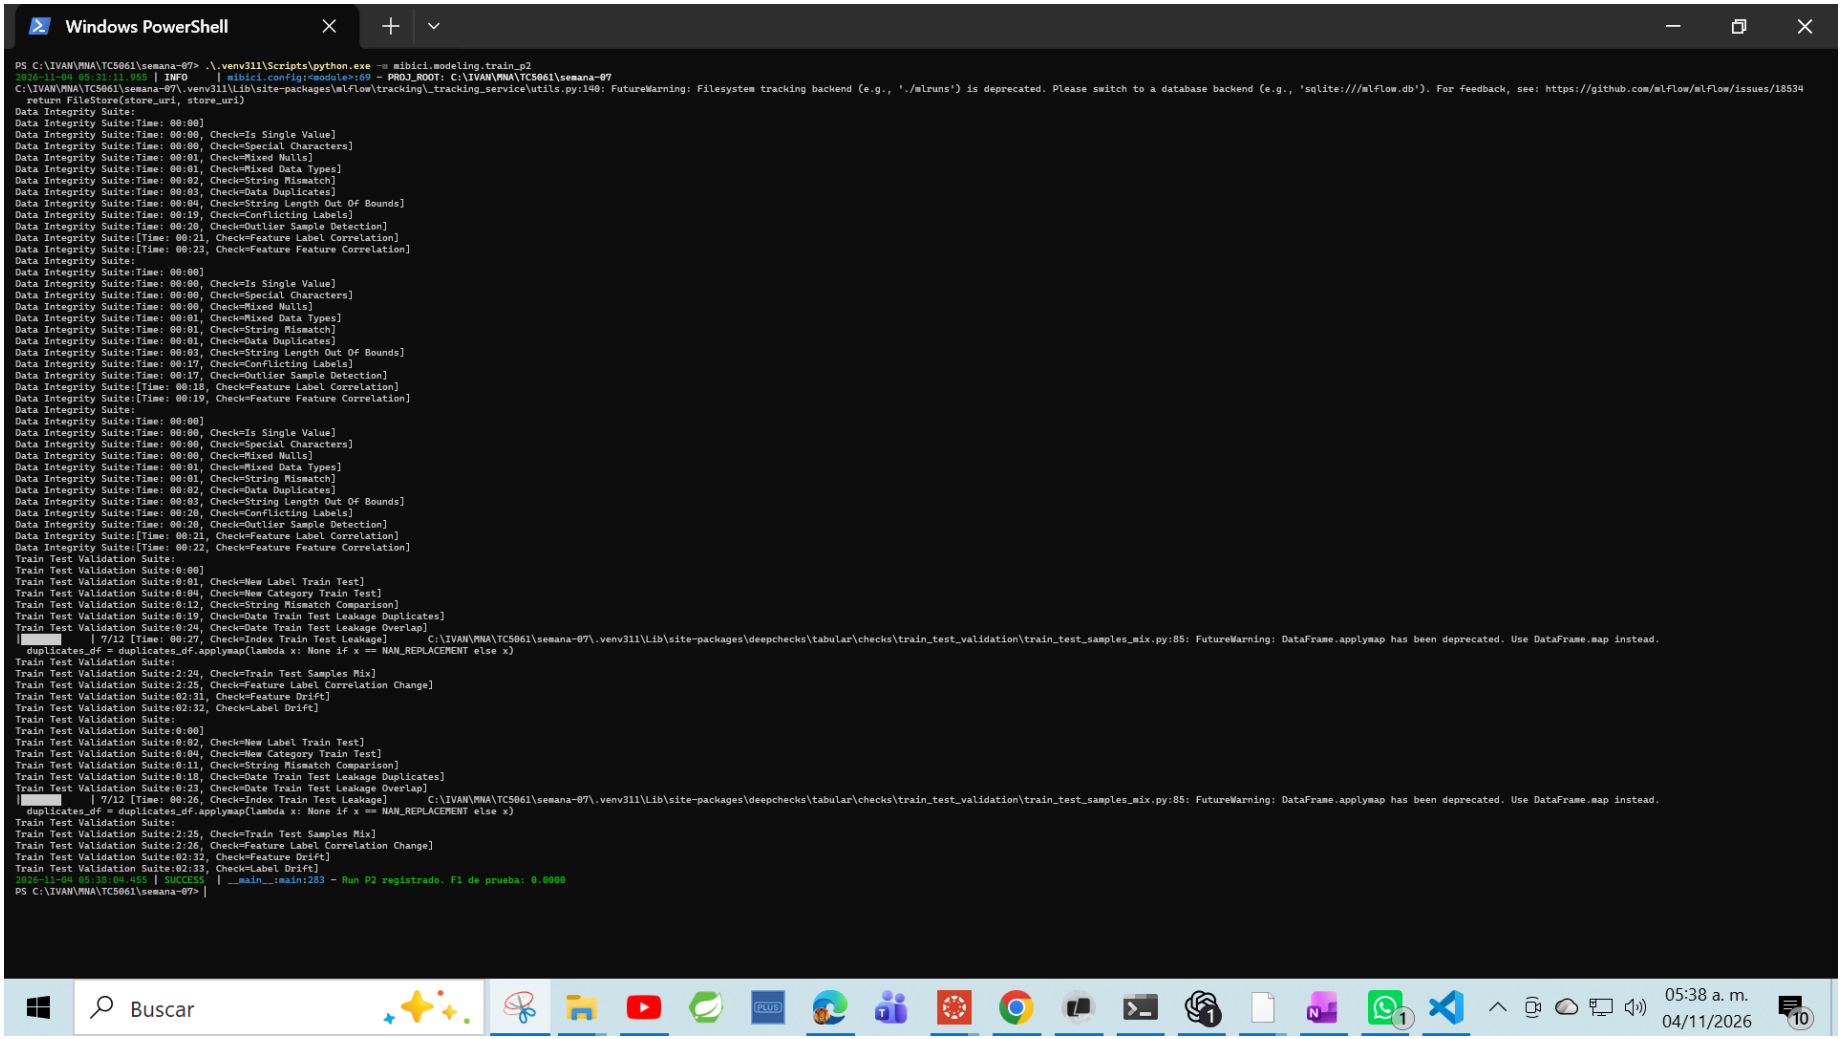


Figura C.3. Ejecución de DeepChecks para P3

Captura de la ejecución del pipeline, la suite de DeepChecks y el mensaje final de registro.

