MACHINE LEARNING CANVAS

Designed for: Equipo 46 iaOps | Designed by: **Axel Rabago** | Date: 1/10/2026 | Iteration: 1 .

PREDICTION TASK

P1 REGRESIÓN: viajes iniciados por estación en la próxima hora; resultado: conteo ≥ 0.

P2 CLASIFICACIÓN: alerta binaria de presión de flujos en la próxima hora si |salidas − llegadas| / capacidad ≥ 0.25 (umbral provisional). El signo orienta el tipo de riesgo; NO equivale a inventario real.

P3 CLUSTERING: agrupar estaciones por su perfil histórico de uso (sin clase objetivo). P1/P2 se verifican al cerrar la hora; P3 al completar el periodo de análisis.

DECISIONS

P1: anticipar la demanda y proponer redistribución preventiva de bicicletas por estación.

P2: ordenar inspecciones; más salidas que llegadas sugiere posible escasez de bicicletas, y el caso inverso, de anclajes. Confirmar con inventario real antes de actuar.

P3: identificar tipos de estaciones para ajustar cobertura y orientar la expansión. El personal decide; el modelo solo respalda la priorización.

VALUE PROPOSITION

USUARIOS: operación y rebalanceo de MiBici (P1 y P2); planeación del sistema y urbana (P3).

NECESIDAD: la demanda cambia por estación, horario y día; los flujos de entrada y salida pueden desbalancearse; las estaciones tienen perfiles distintos.

BENEFICIO: anticipar viajes, focalizar verificaciones y reconocer grupos comparables para distribuir mejor la flota y fundamentar decisiones de cobertura.

INTEGRACIÓN PROPUESTA: reporte horario, tabla de alertas y mapa de clústeres para revisión humana.

ALCANCE: prototipo analítico académico, no despliegue productivo ni medición directa de bicicletas disponibles.

DATA COLLECTION

mibici/dataset.py
descarga automáticamente los CSV mensuales (ene–sep 2026) y el catálogo de estaciones (sep 2026); normaliza esquemas, codificación y fechas; genera Parquet.

Un manifiesto documenta conteos, SHA-256 y versión lógica d038fe16493d.

ACTUALIZACIÓN PROPUESTA: incorporar nuevos meses, validar cambios de esquema, generar nuevos hashes y reentrenar tras controles de calidad.
No se declara una ingesta continua ya operativa.

DATA SOURCES

FUENTE ABIERTA:
mibici.net/es/datos-abiertos/
datos_abiertos_AAAA_MM.csv (viajes, tiempos, origen y destino).

ESTACIONES:
nomenclatura_2026_09.csv
(identificador, coordenadas y capacidad).

SEGÚN MANIFIESTO DEL EQUIPO: 9 meses, 3,361,307 viajes procesados y 484 estaciones.

LÍMITES: sin inventario histórico; el catálogo de septiembre podría no describir meses anteriores. No modelar atributos personales.

IMPACT SIMULATION

SIMULACIÓN: validación en julio y prueba en ago–sep 2026, sin intervenciones reales.

P1: errores MAE/RMSE y mejora frente a naive semanal; revisar subestimaciones de alta demanda.

P2: costo relativo preliminar de falso negativo = 3 y falso positivo = 1 (hipótesis, no pesos económicos reales); confirmar alertas con operación.

P3: estabilidad temporal y utilidad de segmentos para planear.

DESPLIEGUE: solo tras superar baselines, validar datos y privacidad, y revisar cobertura y equidad por zona.

MAKING PREDICTIONS

P1/P2: predicciones por LOTES al comienzo de la hora t, con horizonte [t, t+1 h) y datos disponibles antes de t.

P3: grupos recalculados periódicamente (frecuencia mensual propuesta); no predice eventos futuros.

FASE 1: ejecución local por la línea de comandos; sin API ni operación en tiempo real.

TIEMPO OBJETIVO: producir reportes en minutos (por validar). Recursos: Python y CPU local; evaluar latencia de ingesta e inferencia.

BUILDING MODELS

TRES PIPELINES:
P1 naive estacional vs Random Forest/gradient boosting para regresión;
P2 Dummy/regla vs Random Forest de clasificación; P3 K-Means inicial vs k ajustado.
P1/P2: entrenamiento ene–jun, validación jul y prueba ago–sep 2026; P3 perfiles construidos con histórico pasado y pruebas de estabilidad.

MLflow registra runs P1/P2/P3, versión de datos, commit, parámetros, métricas y artefactos.

Reentrenamiento mensual PROPUESTO ante datos nuevos o drift. Equipo local con scikit-learn/CPU.

FEATURES

UNIDAD P1/P2: estación × hora, incluyendo horas con cero viajes. PREDICTORES: hora, día, fin de semana; conteos previos de salidas/llegadas; medias móviles desplazadas.

P2: balance pasado normalizado por capacidad válida (>0). La presión de la hora futura sirve solo de ETIQUETA, nunca como predictor.

P3: intensidad, perfil horario, picos, uso en fin de semana y balance de flujos históricos; escalar antes de agrupar.

MONITORING

P1: MAE/RMSE; P2: Recall/F1 y alertas falsas; P3: Silhouette/DBI y estabilidad. MLflow: métricas val/test, versión y commit. Si opera: revisar datos a diario y drift cada mes.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO

What your canvas is for

A filled canvas does 4 jobs, and each one needs certain boxes filled in with care.

- **Deciding what's worth building.** Put each idea on its own canvas and you can compare the ideas on the same terms: what each could gain in a year, and whether the outcomes a model would learn from were ever recorded. That takes dollar amounts in the Impact Simulation box, and a named person in the Value Proposition box who acts on each prediction.
- **Agreeing on what gets built.** Some of the choices that set a system's value look technical, but they're business decisions. What counts as a lost customer: 60 days without buying, or 90? How far ahead do you predict? How many flagged cases can your team act on? On the canvas, business, data and engineering make these choices together, instead of leaving them to whoever writes the code.
- **Knowing when the model is good enough.** The Impact Simulation box sets the performance the model has to reach to pay off. Test the model on enough of the cases you're predicting: 35,000 machine-hours of data can hold just 3 failures, too few to measure anything.
- **Learning after launch.** If acting on a prediction changes the outcome, keep a small share of flagged cases untouched and record that share in the Decisions box, so you can see what your action changed.

Whatever you can't answer is the work left before anyone writes code.

"The Canvas allowed us to structure and focus our delivery sprints. The ML system went live in June 2020 and still is."
— Christian Schiller, Senior IT & Enterprise Architect, Deutsche Telekom

Book a project review

Louis Dorard created the canvas in 2015. Book a free 30-minute call, then send him your canvas draft, or a few lines about the project if you haven't started one. He prepares the call from what you send, and you'll leave knowing where the project is likely to break, and what to check before anyone builds it.

Book a 30-minute call →

Reference the Machine Learning Canvas

If you need to reference the Canvas formally (e.g. in documentation or publications), you may use:

```
@misc{mlc,
  title  = "Machine Learning Canvas",
  author = "Louis Dorard (OWNML)",
  url    = "https://www.ownml.co/",
  year   = "2015"
}
```

"MLC played an essential role in a positive project outcome. It is now being used throughout the organization."
— Daitan, now part of Coforge, a global IT services firm