Tecnológico de Monterrey

Proyecto MiBici: propuesta y base reproducible

Operaciones de aprendizaje automático (Gpo. 10)

Equipo 46:

- Iván Plata Garnica
- Axel Fernando Rábago Díaz
- Mónica Maria Ramirez Mejia

Resumen ejecutivo

El proyecto propone una base reproducible de aprendizaje automático sobre los datos abiertos del sistema de bicicletas compartidas MiBici, en el Área Metropolitana de Guadalajara. Se abordan tres preguntas de negocio: estimación de viajes iniciados por estación en la siguiente hora (P1, regresión), identificación de riesgo aproximado de desequilibrio entre retiros y devoluciones (P2, clasificación) y segmentación de estaciones por sus patrones históricos de uso (P3, clustering).

Se adopta como periodo inicial enero–septiembre de 2026 y un catálogo de estaciones con corte a septiembre de 2026. El manifiesto incluido en la instantánea del repositorio declara 3,362,065 viajes brutos, 3,361,307 viajes procesados, 484 estaciones y la versión lógica d038fe16493d; son conteos reportados por el equipo y aún requieren una prueba independiente desde las fuentes originales. El ML Canvas oficial OWNML v1.2, completado para P1, P2 y P3, está incorporado íntegramente como Anexo A y determina las decisiones operativas propuestas, los enfoques de evaluación y las limitaciones declaradas.

El diseño considera una ingesta automatizada en mibici/dataset.py, salida normalizada en Parquet y manifiesto SHA-256; funciones reutilizables en mibici/features.py; modelos base y candidatos ejecutados desde scripts; MLflow Tracking para parámetros, métricas, tags y artefactos; y colaboración controlada mediante GitHub Flow. Tal como establece el Canvas, las predicciones P1 y P2 se proponen por lotes al inicio de cada hora y la actualización de los perfiles P3 sería periódica. No existe todavía evidencia de ejecución en producción ni un beneficio económico validado (Huyen, 2022; MLflow, s. f.).

Ficha de control

Elemento	Definición / evidencia
Repositorio del equipo	https://github.com/axelR07/TC5061-Proyecto-Equipo46
Dataset y periodo	CSV mensuales de viajes, enero–septiembre 2026, y nomenclatura_2026_09.csv.
Versión declarada de datos	d038fe16493d · manifiesto data/manifest/data_manifest.json.
Unidad P1 / P2	Estación × hora; pronóstico de la siguiente hora, emitido justo al comenzar la ventana.
Unidad P3	Estación; perfil agregado construido únicamente con datos históricos del periodo de entrenamiento.
Experimento MLflow propuesto	mibici-equipo46.

1. Contexto, oportunidad y usuarios

MiBici publica archivos mensuales de viajes y una nomenclatura de estaciones. Los viajes describen retiros, devoluciones, estaciones y marcas temporales; el catálogo incorpora ubicaciones y capacidad de anclajes. La información permite estudiar patrones temporales y espaciales, aunque no incluye una serie histórica de existencias de bicicletas o anclajes libres, por lo que no constituye un sensor directo de ocupación (Mi Bici, s. f.-a).

Los usuarios previstos son: personal de operación para anticipar demanda horaria (P1), equipo de rebalanceo para priorizar revisiones por posible desbalance de flujos (P2) y personal de planeación para caracterizar estaciones por comportamiento (P3). Las salidas apoyarían decisiones humanas; ninguna predicción implica ejecutar de forma automática traslados de bicicletas o cambios en infraestructura.

Objetivo general

Diseñar y evaluar una solución reproducible de Machine Learning basada en datos abiertos de MiBici, capaz de estimar demanda de viajes, identificar señales aproximadas de desequilibrio operativo y agrupar estaciones con patrones comparables, documentando decisiones técnicas, limitaciones, trazabilidad de datos y experimentos.

Objetivos específicos

- Construir observaciones consistentes en una granularidad temporal y espacial apropiada para cada pregunta.
- Definir variables objetivo, predictores disponibles al momento del pronóstico, baselines y modelos candidatos justificables.
- Aplicar cortes temporales y controles explícitos contra fuga de información futura.
- Documentar arquitectura, datos, variables, estrategias de evaluación y controles de privacidad.
- Permitir experimentos reproducibles y rastreables por versión de datos, semilla y commit de Git.

2. Inventario y selección del conjunto de datos

Las fuentes oficiales son el portal MiBici de datos abiertos (https://mibici.net/es/datos-abiertos/) y la nomenclatura de estaciones publicada desde ese portal. Se seleccionó enero–septiembre de 2026 porque existe una implementación de ingesta del equipo con cobertura mensual consecutiva, y porque nueve meses permiten observar días laborales, fines de semana y variaciones intraperiodo sin introducir incompatibilidades históricas innecesarias. Esto no equivale a cubrir un ciclo anual completo; la estacionalidad anual solo podrá tratarse como limitación o con datos adicionales.

Indicador	Valor reportado	Estatus
Meses procesados	9 (enero a septiembre de 2026)	Manifiesto del repositorio
Viajes brutos	3,362,065	Manifiesto del repositorio
Viajes descartados	758	Diferencia brutos – procesados
Viajes procesados	3,361,307	Manifiesto del repositorio
Estaciones en catálogo	484	Catálogo corte septiembre 2026
Estaciones marcadas ex-	14	Resumen de ingesta del repositorio
Capacidad cero	4 estaciones	Resumen de ingesta; excluir en índices / capacidad
Versión lógica de datos	d038fe16493d	HASH de insumos descrito por el equipo

Fuente interna: TC5061-Proyecto-Equipo46, archivos README.md, mibici/config.py, data/manifest/data_manifest.json y reports/ingesta_resumen.md. El conteo de estaciones pertenece al catálogo; no presupone que todas estuvieron activas a lo largo de los nueve meses.

2.1. Variables de origen y política de uso

Campo normalizado	Uso en la propuesta	Precaución
start_time, origin_id	Salidas por estación y hora; objetivo de P1.	No usar salidas de la hora pronosticada como predictor.
end_time, destination_id	Llegadas por estación y hora; proxy de P2.	Computar llegadas por tiempo de fin, no de inicio.
station_id, lat, lon	Identificación y mapa de clústeres P3.	Validar coordenadas; no usarlas como única base del clúster.
capacity	Escalamiento de flujos y denominador de P2.	Capacidad 0 inválida; catálogo no histórico.
trip_id	Control de duplicados.	No usar como predictor; no registrar identificadores individuales.
gender, birth_year, duration_min	No requeridos para baselines propuestos.	Excluir del modelado inicial para minimizar tratamiento personal.

La ingesta ya elimina user_id. Para la primera iteración, se propone no utilizar género, año de nacimiento ni secuencias individuales. Los artefactos públicos serán agregados por estación/periodo, sin trayectorias individuales. El portal dispone de un aviso de privacidad, pero en la página revisada no se encontró una licencia explícita específica para el dataset (por ejemplo, CC BY); por ello no se atribuye una licencia no verificada y debe confirmarse la autorización de reutilización y sus condiciones antes de publicar archivos derivados (Mi Bici, s. f.-a, s. f.-b).

2.2. Esquema temporal y prevención de fuga

Fase	Periodo	Objetivo
Entrenamiento	01-ene-2026 a 30-jun-2026	Aprender patrones y ajustar transformaciones.
Validación	01-jul-2026 a 31-jul-2026	Comparar modelos y fijar hiperparámetros.
Prueba final	01-ago-2026 a 30-sep-2026	Medir generalización sin reoptimizar decisiones.

Los ejemplos de P1 y P2 se agrupan por estación y hora. Para una ventana [t, t+1 h) los predictores solo deben contener información observada antes de t; la etiqueta se construye con sucesos ocurridos dentro de la ventana futura. Las medias móviles y lags se calculan tras desplazar la serie al pasado. No se deben ajustar imputadores, escaladores ni parámetros de modelos con datos de validación/prueba. Durante el inicio de la serie se utilizará historial incompleto documentado o se excluirán filas sin los lags necesarios (scikit-learn developers, s. f.-a).

3. Formulación de P1 · Regresión de demanda

3.1. Pregunta operacional

¿Cuántos viajes se iniciarán en la estación s durante la siguiente hora, utilizando únicamente los movimientos conocidos hasta el comienzo de esa hora?

Elemento	Definición propuesta
Entidad y granularidad	Una estación × una hora calendario. Incluir horas sin salidas reales para evitar sesgo de selección.
Momento de predicción	Inicio de la hora t; datos disponibles con marca temporal < t.
Horizonte	Próxima hora [t, t + 1 h).
Objetivo	$y_1(s,t)$ = número de viajes con origin_id=s y start_time∈[t,t+1 h). Entero ≥0.
Usuario / decisión	Operación; anticipar demanda y planear disponibilidad o posicionamiento de flota.
Baseline	Naive estacional: viajes de la misma estación en la misma hora 7 días antes; fallback a promedio histórico pasado de estación/hora.
Modelo candidato	HistGradientBoostingRegressor o RandomForestRegressor sobre variables tabulares; comparar costo y precisión.
Métrica principal	MAE en viajes por estación-hora. Secundarias: RMSE y WAPE con denominador total no nulo.

3.2. Variables y construcción

Predictores disponibles antes del pronóstico: hora del día, día de semana, fin de semana, indicadores de volumen previo con lags de 1, 24 y 168 horas, promedios históricos móviles de 24 y 168 horas, volumen de llegadas ya observadas y estación identificada/codificada. La capacidad y coordenadas se reservarán como atributos auxiliares sujetos a validación de vigencia histórica.

El baseline semanal es interpretable: para un lunes a las 08:00 se espera la demanda observada el lunes anterior a las 08:00 en la misma estación. Su utilidad operativa consiste en constituir una referencia que cualquier modelo más

complejo debe superar. MAE indica, en unidades de viajes, cuánto se equivoca en promedio el pronóstico; RMSE permite observar el efecto de errores excepcionalmente grandes.

3.3. Evaluación y aceptación

Comparar MAE de validación contra la línea base; posteriormente fijar la configuración y evaluar una sola vez en agosto–septiembre. Presentar error por estación, hora pico y día de semana. Una mejora estadística no se interpretará automáticamente como ahorro logístico sin cuantificar costos de redistribución y errores de pronóstico.

4. Formulación de P2 · Clasificación de riesgo aproximado

4.1. Alcance y limitación fundamental

El archivo de viajes no registra inventario de bicicletas ni anclajes libres. Por ello no es posible construir etiquetas de desabasto/saturación observados. P2 se formulará explícitamente como clasificación de un proxy de presión operativa basado en el balance neto de flujos durante la siguiente hora, no como probabilidad validada de estación vacía o llena.

4.2. Objetivo propuesto y regla transparente

Para cada estación s y ventana horaria t, definir D(s,t)=salidas registradas durante [t,t+1 h), A(s,t)=llegadas registradas durante la misma ventana y C(s)=capacidad válida de anclajes del catálogo (C>0). Se define $B(s,t)=[D(s,t)-A(s,t)]/C(s)$. Una señal de riesgo binario es $y_2(s,t)=1$ cuando $|B(s,t)|\geq\tau$ y 0 en otro caso; como punto inicial de diseño se fija $\tau=0.25$. Si $B\geq\tau$, el flujo neto apunta a vaciamiento; si $B\leq-\tau$, a presión de ocupación. Estas etiquetas derivan del flujo, no demuestran agotamiento de bicicletas ni anclajes.

El umbral 0.25 es una hipótesis de diseño; no se presenta como estándar publicado ni como valor empíricamente validado. Debe informarse la prevalencia resultante por periodo/estación y estudiar sensibilidad con $\tau=0.15$ y $\tau=0.35$ sin reinterpretar retrospectivamente la etiqueta como un evento real. Las estaciones con capacidad cero o no verificable se excluyen de la construcción de esta etiqueta, reportando sus cantidades.

Elemento	Definición propuesta
Granularidad / horizonte	Estación × hora; riesgo aproximado en la siguiente hora.
Objetivo	$y_2=1$ si $\|D-A\|$/capacidad ≥ 0.25; $y_2=0$ en caso contrario (proxy).
Predictores	Lags temporales de retiros/llegadas, balance previo, día/hora, promedio móvil previo, capacidad solo con caveat.
Baseline	DummyClassifier(strategy="most_frequent") y regla histórica simple: señal de presión si $\|B(s,t-168\ h)\|\geq\tau$.
Modelo candidato	RandomForestClassifier con class_weight="balanced" como punto inicial.
Métrica principal	Recall de la clase riesgo; secundarias: Precision, F1, PR-AUC y matriz de confusión.
Usuario / decisión	Rebalanceo: priorizar estaciones para verificación manual y planificación operativa.

4.3. Justificación de métricas y costos

Se prioriza Recall porque un falso negativo del proxy de presión puede dejar sin revisión una estación con fuertes movimientos netos; una alerta falsa también puede implicar inspecciones y costos innecesarios, por lo que se calcularán Precision, F1 y PR-AUC y se documentará la matriz de confusión. El ML Canvas plantea para simulación una relación de costos relativos FN:FP = 3:1 como HIPÓTESIS de trabajo; no representa costos económicos medidos y requiere validación con personal de operación. Los umbrales del indicador y de decisión se fijarán usando validación, nunca prueba final. Se mostrará la prevalencia de la clase por partición.

5. Formulación de P3 · Clustering de estaciones

5.1. Pregunta analítica

¿Qué grupos de estaciones presentan perfiles de uso similares, y cómo se distribuyen espacialmente esos grupos en el Área Metropolitana de Guadalajara? La salida no es una predicción supervisada sino una segmentación descriptiva que apoyaría decisiones de planeación.

Elemento	Definición propuesta
Unidad	Una fila por estación elegible; perfil construido exclusivamente con datos de enero–junio de 2026.
Variables	Viajes promedio diarios, proporción de actividad en punta matutina y vespertina, ratio fin de semana, variabilidad, balance neto horario y rotación relativa si capacidad válida.
Normalización	StandardScaler ajustado sobre perfiles del periodo de construcción, no sobre meses posteriores.
Baseline	K-Means con k=3, random_state=42 y n_init explícito.
Candidatos	K-Means con selección de k en {2,3,4,5,6}; alternativamente aglomerativo para comparar patrones.
Métricas	Silhouette (más alto favorecido) y Davies–Bouldin (más bajo favorecido); tamaño de clúster e interpretabilidad.
Usuarios / decisión	Planeación urbana; detectar tipologías de estaciones y orientar análisis de expansión o ajuste de capacidad.

5.2. Interpretación y validación

El agrupamiento se realiza por patrones operativos, no directamente por latitud/longitud para evitar que el resultado sea únicamente una partición geográfica. Después se grafican los grupos sobre las coordenadas validadas. Se revisan tamaños, promedios por variable, estabilidad de asignaciones al contrastar con julio–septiembre y sensibilidad a k. Las etiquetas de clúster son identificadores arbitrarios y no equivalen a categorías oficiales de MiBici.

Como criterio operativo, un clúster podría describir estaciones de alto flujo, estaciones con demanda concentrada en la mañana u otras tipologías; estos nombres se asignarán solo después de observar centroides y distribuciones reales, no antes.

6. ML Canvas

Se incorporó el Machine Learning Canvas oficial v1.2 de Louis Dorard, con sus diez bloques originales y créditos/licencia de OWNML preservados (Anexo A). El contenido se desarrolló específicamente para MiBici y es consistente con las secciones 2 a 5 y 7 a 10 de este informe. El Canvas se plantea para una solución analítica de tres tareas: P1 y P2 como pronósticos horarios; P3 como segmentación descriptiva sin etiqueta objetivo. El anexo es una reproducción visual del documento oficial completado; el archivo OWNML editado se entrega también en formato DOCX para su resguardo en references/.

1. Propuesta de valor

Beneficiarios: operación y rebalanceo del sistema (P1 y P2) y planeación del servicio/urbana (P3). Se propone responder a variaciones por estación, hora y día: P1 anticipa demanda; P2 prioriza la revisión humana de flujos desbalanceados; P3 describe perfiles de uso. Las interfaces previstas son reporte horario, tabla de alertas y mapa de clústeres. El alcance es un prototipo académico, sin despliegue ni decisiones automatizadas.

2. Tarea predictiva / analítica

P1: regresión del número entero de viajes iniciados por estación en [t, t+1 h). P2: clasificación binaria del proxy |salidas−llegadas|/capacidad≥0.25 en la siguiente hora; el signo del balance identifica presión de retiro o devolución,

pero NO mide bicicletas disponibles. P3: agrupamiento sin supervisión de estaciones por su perfil histórico (una observación por estación). Las etiquetas P1/P2 se conocen al concluir la hora.

3. Decisiones

P1: apoyar la distribución preventiva de bicicletas; P2: ordenar inspecciones y verificación manual, confirmando inventario real antes de actuar; P3: orientar análisis de cobertura, capacidad y expansión. Ningún resultado se interpreta como orden operacional automática. Los responsables y reglas de actuación definitiva deben validarse con el operador.

4. Fuentes de datos

Viajes mensuales abiertos (datos_abiertos_AAAA_MM.csv) y nomenclatura_2026_09.csv del portal de MiBici. Periodo de trabajo enero–septiembre de 2026; el manifiesto de equipo declara 9 meses, 3,361,307 viajes procesados y 484 estaciones. Existen marcas de inicio/fin y estaciones; no existe telemetría histórica de disponibilidad. Los atributos del catálogo de septiembre pueden no describir meses anteriores.

5. Recopilación / ingesta

El código mibici/dataset.py está destinado a descargar, normalizar columnas/codificación/fechas y guardar Parquet. El manifiesto incluye cantidades, hashes SHA-256 y versión lógica d038fe16493d, pendiente de validación desde un clon limpio. La actualización con meses nuevos, controles de esquema y reentrenamiento es una propuesta; no se presenta como ingesta automática continua ya implementada. Evitar subir datos crudos y credenciales al repositorio.

6. Features

P1/P2: estación×hora, incluso ceros; calendario, lags de salidas/llegadas (1, 24, 168 h), medias móviles con shift(1) y balance pasado. En P2 la presión FUTURA solo determina y_2, nunca los predictores; la capacidad se usa exclusivamente si C>0 y su vigencia histórica se ha justificado. P3: intensidad, mezcla horaria, fines de semana y balance históricos por estación, normalizados antes de agrupar. Excluir identificadores y variables personales.

7. Construcción de modelos

Se proponen tres pipelines: P1 naive semanal y Random Forest/boosting de regresión; P2 DummyClassifier/regla histórica y Random Forest Classifier; P3 K-Means k=3 de referencia y selección de k entre 2 y 6. P1/P2 se entrenan con enero–junio, validan en julio y se prueban en agosto–septiembre de 2026; P3 se construye sobre perfiles del histórico inicial y comprueba estabilidad posterior. Runs con versión de datos, commit y artefactos en MLflow.

8. Predicciones / uso

P1 y P2 se ejecutarían en lotes al comienzo de la hora t, utilizando únicamente datos disponibles antes de t; un reporte generado en minutos es un objetivo de diseño pendiente de prueba. P3 ofrecería grupos de estaciones revisados periódicamente (cadencia mensual PROPUESTA) sin pronosticar un evento futuro. Primera fase local en Python/CPU, sin API operativa ni infraestructura en tiempo real.

9. Evaluación e impacto

P1: MAE/RMSE por estación-hora frente a naive semanal y análisis de horas pico. P2: Recall/Precision/F1/PR-AUC y matriz de confusión; hipótesis para simular costos relativos FN:FP=3:1, por validar con operador. P3: Silhouette, Davies–Bouldin, tamaños e interpretabilidad de grupos; estabilidad temporal. Cualquier beneficio logístico/económico deberá cuantificarse y validarse antes de justificar despliegue.

10. Monitoreo y riesgos

MLflow conservará parámetros, métricas separadas por partición, tags de pregunta/commit y artefactos. Si se desplegara, se plantea vigilar calidad/disponibilidad de datos diariamente y revisar deriva/errores por lo menos cada mes. Riesgos: desbalance de clases, falsa interpretación de P2 como ocupación real, cambios del catálogo, estaciones inactivas, privacidad y diferencias por zonas. Despliegue sujeto a aprobación operativa, seguridad y mejora comprobada sobre los baselines.

6.1. Correspondencia entre el Canvas y la propuesta

La tabla siguiente identifica dónde se justifican los diez componentes del Canvas oficial. De esta forma, las decisiones resumidas en la lámina pueden auditarse en la propuesta técnica.

Bloque OWNML v1.2	Desarrollo técnico correspondiente
Prediction Task	P1 sección 3; P2 sección 4; P3 sección 5.
Decisions / Value Proposition	Sección 1, decisiones de secciones 3–5 y gobernanza en sección 9.
Data Collection / Data Sources	Sección 2 y arquitectura/ingesta en sección 7.
Impact Simulation	Secciones 3.3 y 4.3; métricas y contraste de impacto en sección 8.
Making Predictions	Horizonte P1/P2 (secciones 3 y 4) y actualización P3 (sección 5).
Building Models / Features	Diseños P1–P3 (secciones 3–5); módulos y trazabilidad (secciones 7–8).
Monitoring	Plan experimental en sección 8 y riesgos/controles de sección 9.

7. Arquitectura propuesta y pipeline reproducible

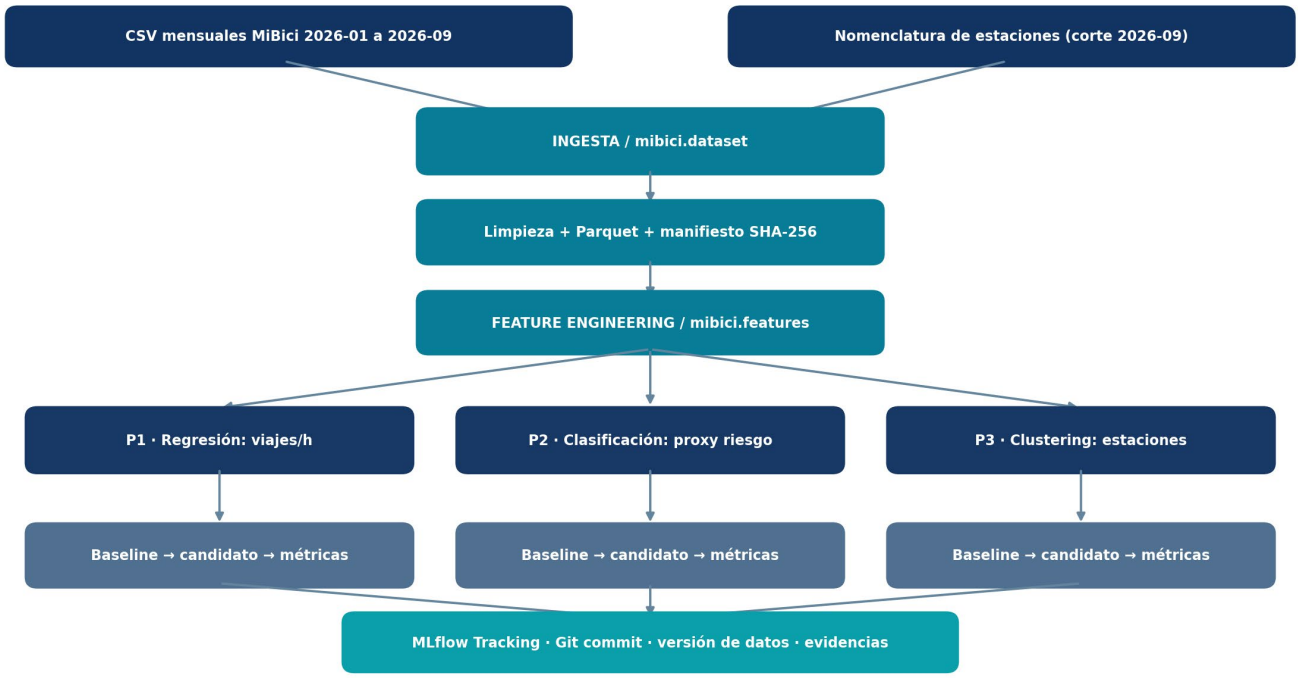


Figura 1. Arquitectura conceptual propuesta para la Fase 1. Elaboración propia (PowerPoint).

La estructura adopta separación de responsabilidades: dataset.py ejecuta ingesta y normalización; features.py construye variables reutilizables; modeling/train.py y/o scripts separados producen baselines y registran artefactos; config.py centraliza rutas, meses y semilla; Git conserva código y manifiestos; MLflow conserva metadatos y artefactos de las ejecuciones. Las herramientas se eligen por transparencia, mantenibilidad y compatibilidad con el repositorio existente (Cookiecutter Data Science, s. f.; Lauchande, 2021; Wilson, 2022).

Componente	Herramienta	Razón técnica
Fuentes	MiBici CSV / catálogo	Disponibilidad pública mensual y atributos por estación.
Ingesta	Python, requests, pandas	Normaliza formatos; integrable con código existente.
Persistencia	Parquet / PyArrow	Lectura columnar y eficiencia para millones de viajes.
Trazabilidad	SHA-256 y JSON versionado en Git	Identifica insumos sin subir datos voluminosos.
Features	Python, pandas, scikit-learn	Funciones reutilizables y pipelines tabulares.
Modelos	scikit-learn	Baselines y algoritmos interpretables reproducibles.
Experimentos	MLflow Tracking	Registro de parámetros, métricas, versiones y artefactos.
Colaboración	GitHub Flow / PR	Cambios revisados, historial y atribución individual.

7.1. Artefactos técnicos previstos

Datos: data/raw (descargas excluidas de Git), data/processed (Parquet excluido) y data/manifest/data_manifest.json (metadatos versionados).

Código: mibici/features.py, mibici/modeling/train.py o módulos de baselines y mibici/config.py.

Evidencias: capturas reales de la interfaz de MLflow y registros de Pull Requests.

La separación entre documentos versionables y salidas no versionables se mantiene mediante .gitignore.

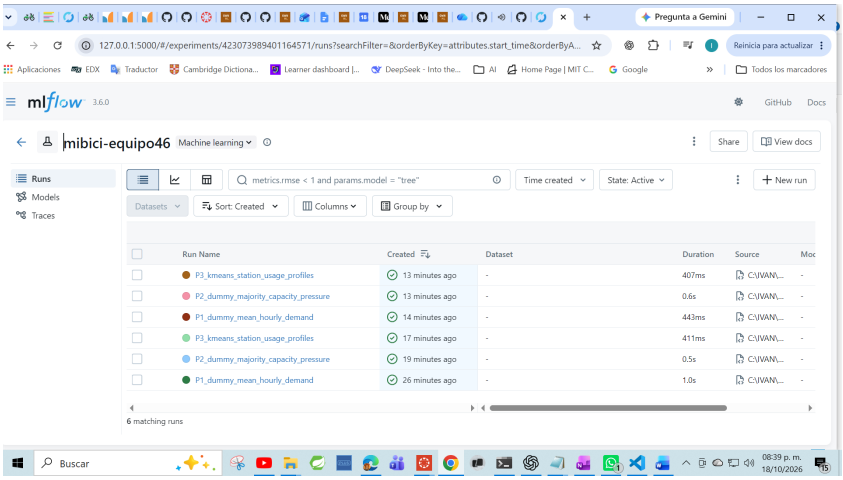
8. Plan de experimentación y trazabilidad MLflow

Se configurará el experimento mibici-equipo46, con ejecuciones generadas desde módulos ejecutables y no exclusivamente desde notebooks. Cada run debe contener pregunta, versión de datos, rango de fechas, código Git, semilla, parámetros de algoritmo, métricas identificadas por conjunto, un artefacto y nombre descriptivo. Se debe conservar evidencia de comparaciones de runs compatibles.

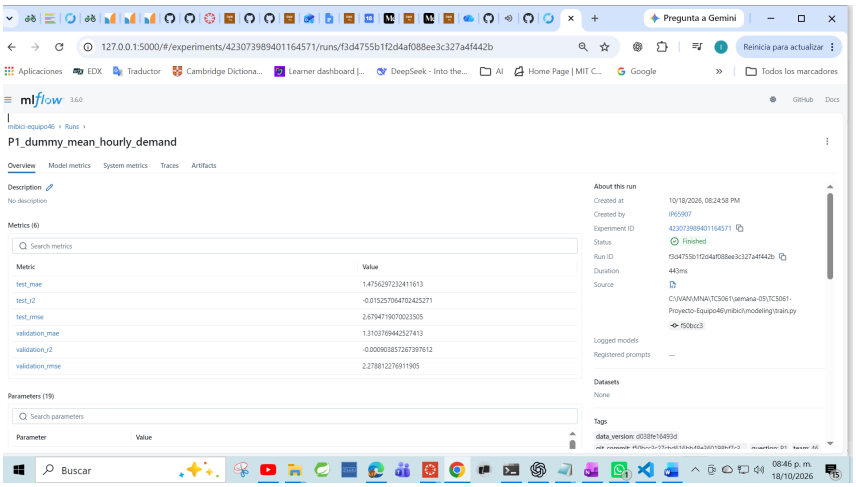
Run mínimo	Parámetros obligatorios	Métricas	Artefacto
P1-baseline-semanal	train_dates, val_dates, test_dates, data_version, git_commit, lag=168	val_mae, val_rmse	reales_vs_predichos.png
P2-baseline-regla	tau=0.25, data_version, git_commit, seed=42	val_recall, val_precision, val_f1	matriz_confusion.png
P3-baseline-kmeans	k=3, seed=42, data_version, git_commit	silhouette, davies_bouldin	mapa_clusters.png

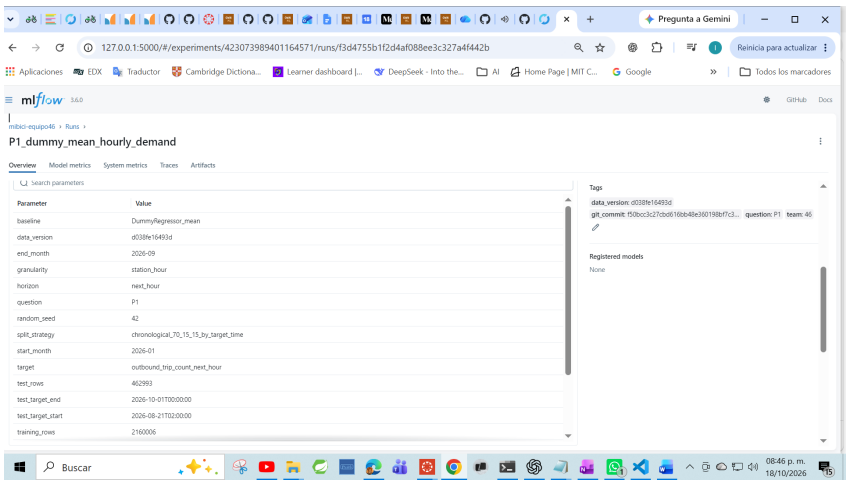
Para satisfacer la cuarta captura exigida (comparación), conviene ejecutar P1-baseline-semanal y P1-candidato (o dos hiperparámetros del mismo problema). No se debe utilizar una comparación P1 versus P2 porque sus métricas tienen unidades y objetivos diferentes. Por ahora no se reportan valores numéricos de modelos: aún no han sido calculados.

8.1. Evidencias

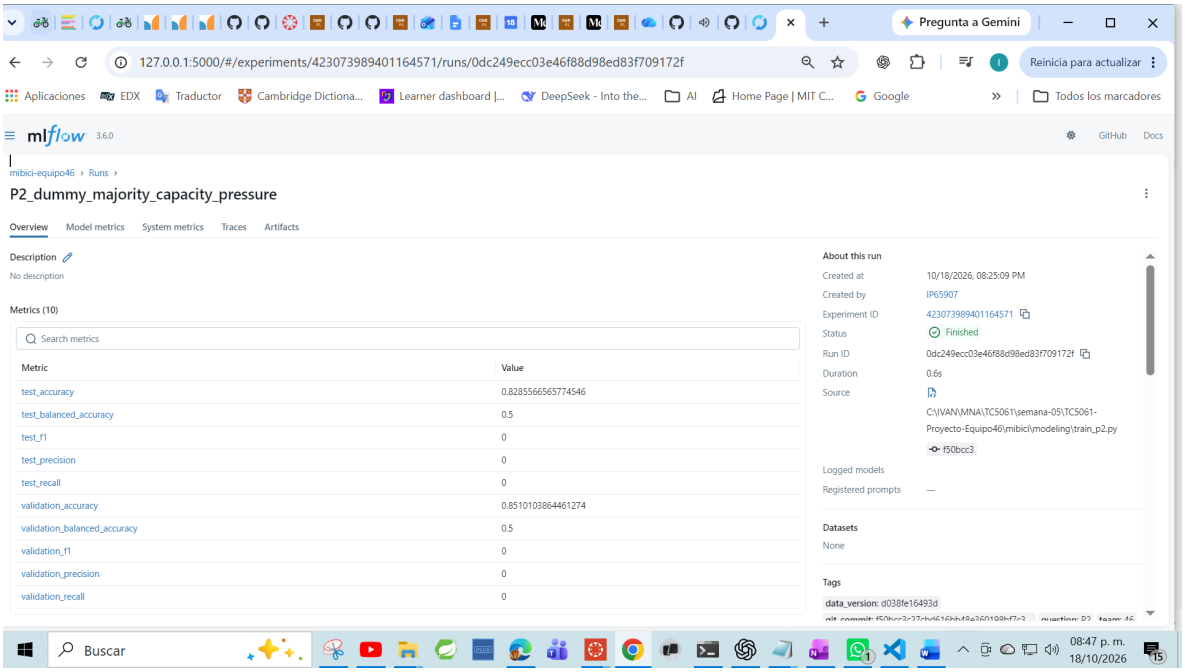


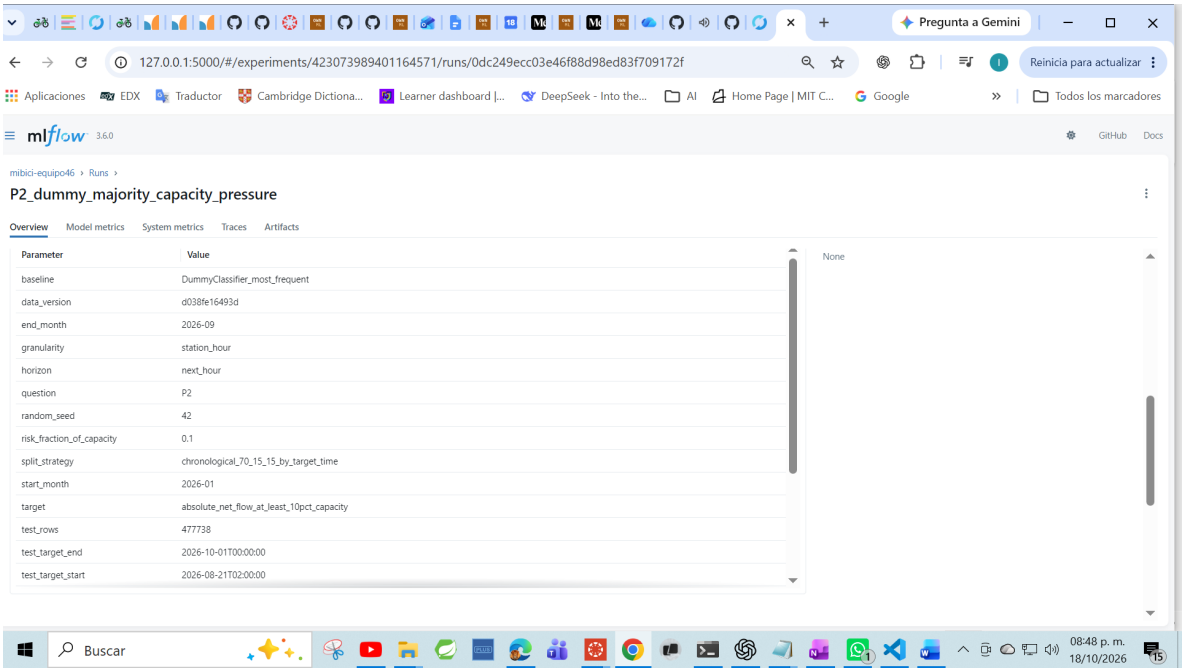
P1:



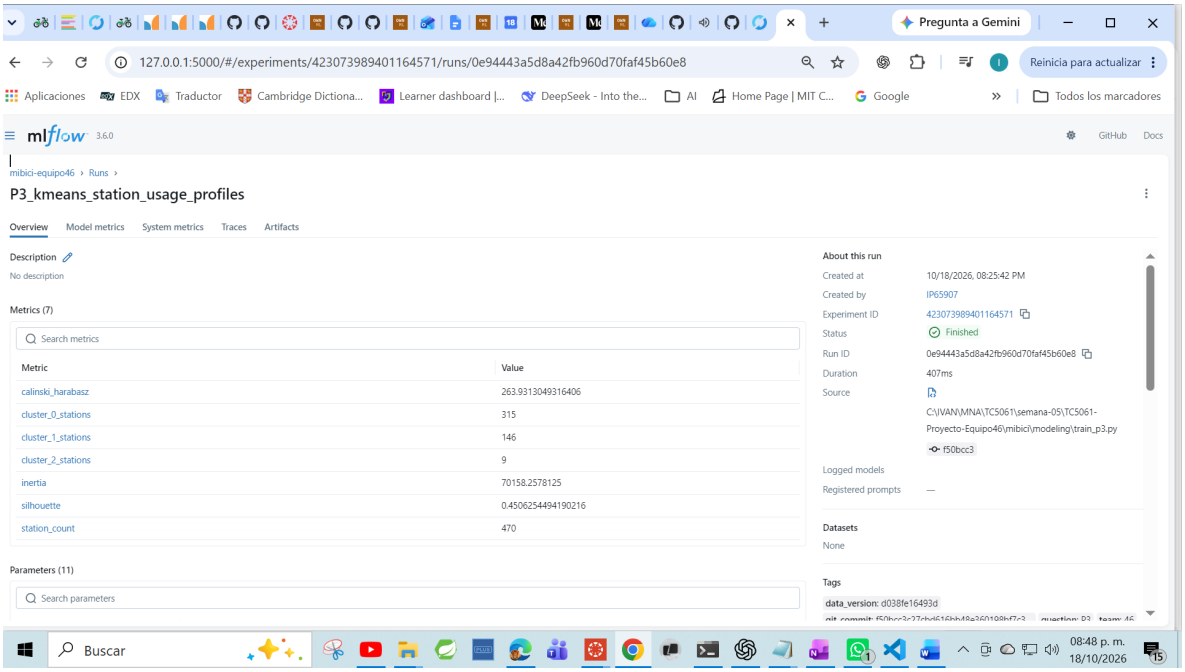


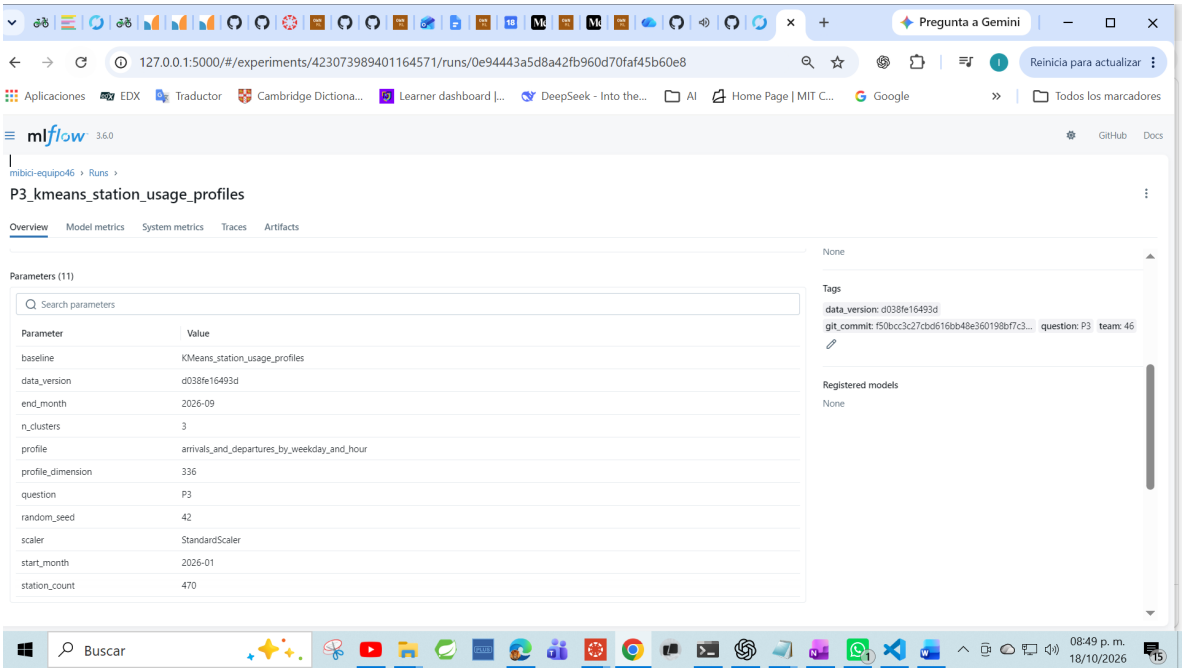
P2:


Pregunta a Gemini
127.0.0.1:5000/#/experiments/423073989401164571/runs/0dc249ecc03e46f88d98ed83f709172f
Reinicia para actualizar
mlflow 3.6.0
GitHub
Docs
mibici-equipo46 › Runs ›
P2_dummy_majority_capacity_pressure
Overview
Model metrics
System metrics
Traces
Artifacts
Description
No description
Metrics (10)
Search metrics
Metric
Value
test_accuracy 0.8285566565774546
test_balanced_accuracy 0.5
test_f1 0
test_precision 0
test_recall 0
validation_accuracy 0.8510103864461274
validation_balanced_accuracy 0.5
validation_f1 0
validation_precision 0
validation_recall 0
About this run
Created at 10/18/2026, 08:25:09 PM
Created by IP65907
Experiment ID 423073989401164571
Status Finished
Run ID 0dc249ecc03e46f88d98ed83f709172f
Duration 0.6s
Source C:\IVAN\MNA\TC5061\semana-05\TC5061-Proyecto-Equipo46\mibici\modeling\train_p2.py
f50bcc3
Logged models
Registered prompts —
Datasets
None
Tags
data_version: d038fe16493d
Buscar
08:47 p. m.
18/10/2026

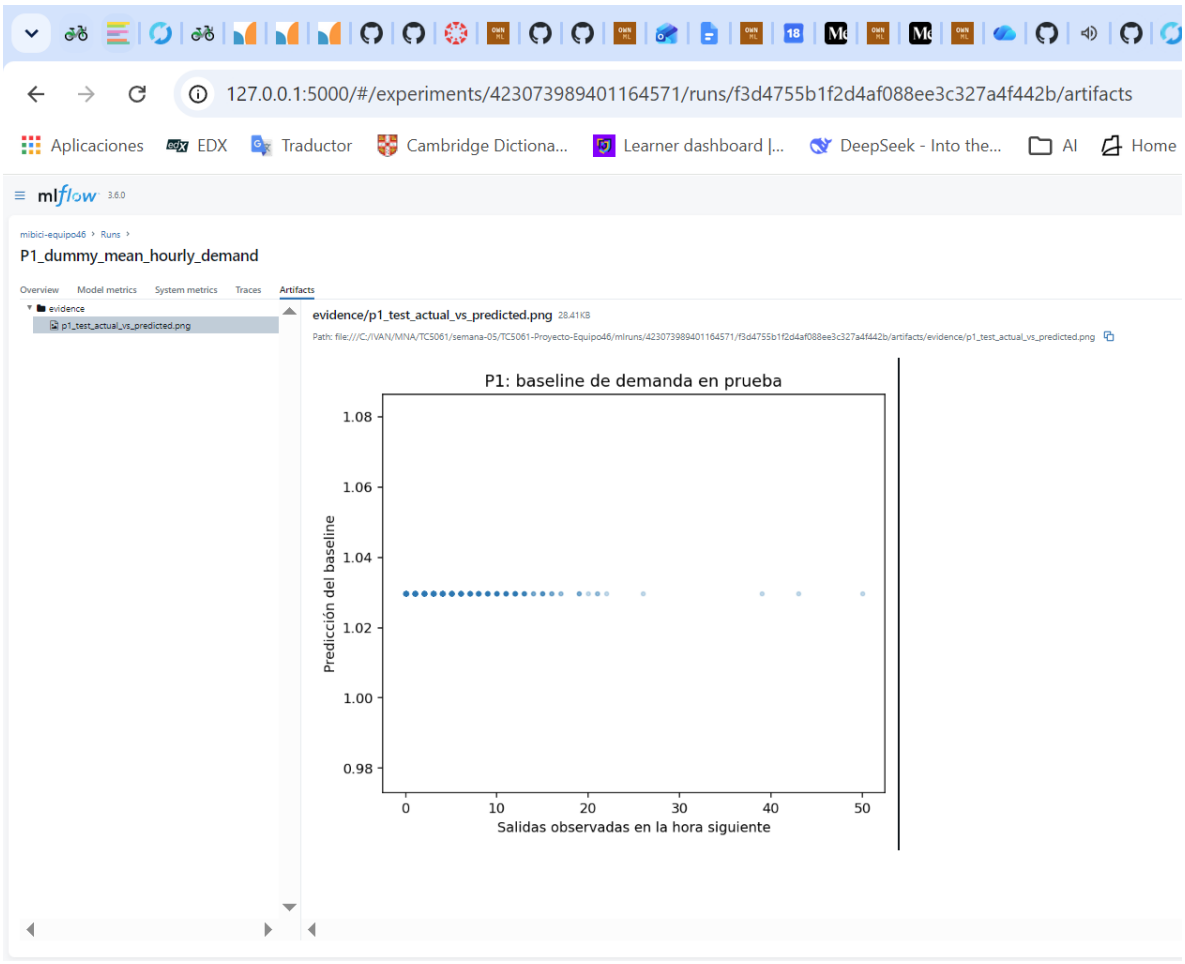

Pregunta a Gemini
127.0.0.1:5000/#/experiments/423073989401164571/runs/0dc249ecc03e46f88d98ed83f709172f
Reinicia para actualizar
mlflow 3.6.0
GitHub
Docs
mibici-equipo46 › Runs ›
P2_dummy_majority_capacity_pressure
Overview
Model metrics
System metrics
Traces
Artifacts
Parameter
Value
baseline DummyClassifier_most_frequent
data_version d038fe16493d
end_month 2026-09
granularity station_hour
horizon next_hour
question P2
random_seed 42
risk_fraction_of_capacity 0.1
split_strategy chronological_70_15_15_by_target_time
start_month 2026-01
target absolute_net_flow_at_least_10pct_capacity
test_rows 477738
test_target_end 2026-10-01T00:00:00
test_target_start 2026-08-21T02:00:00
None
Buscar
08:48 p. m.
18/10/2026

P3:

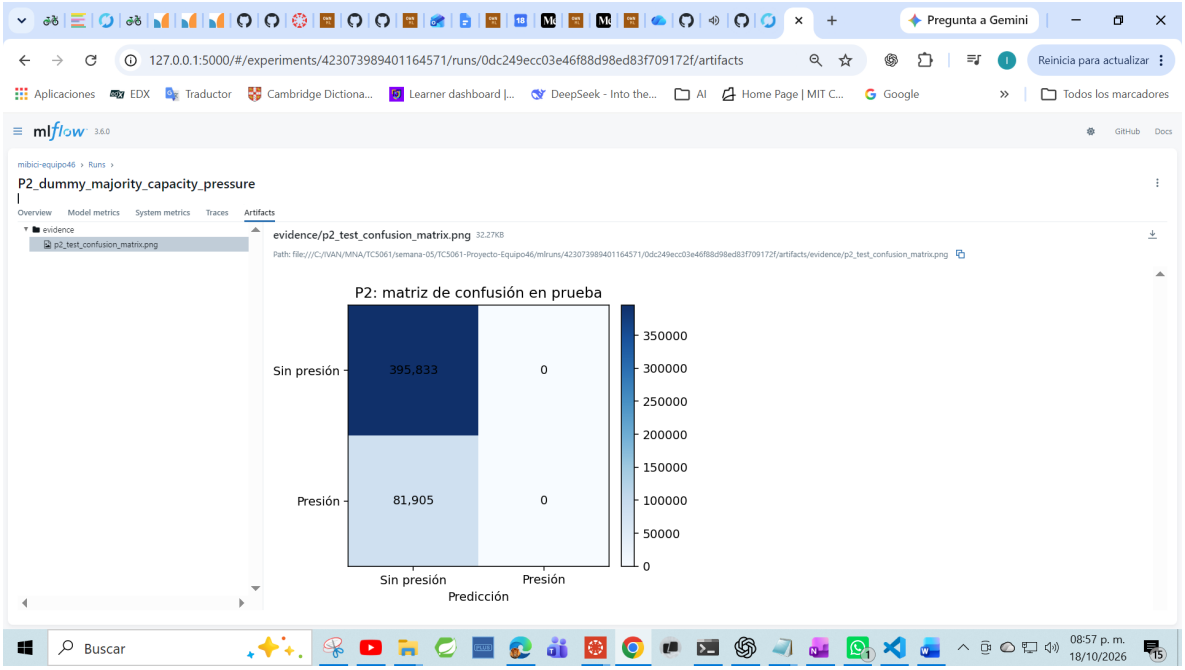

Pregunta a Gemini
127.0.0.1:5000/#/experiments/423073989401164571/runs/0e94443a5d8a42fb960d70faf45b60e8
Reinicia para actualizar
mlflow 3.6.0
GitHub
Docs
mibici-equipo46 › Runs ›
P3_kmeans_station_usage_profiles
Overview
Model metrics
System metrics
Traces
Artifacts
Description
No description
Metrics (7)
Search metrics
Metric
Value
calinski_harabasz 263.9313049316406
cluster_0_stations 315
cluster_1_stations 146
cluster_2_stations 9
inertia 70158.2578125
silhouette 0.4506254494190216
station_count 470
Parameters (11)
Search parameters
About this run
Created at 10/18/2026, 08:25:42 PM
Created by IP65907
Experiment ID 423073989401164571
Status Finished
Run ID 0e94443a5d8a42fb960d70faf45b60e8
Duration 407ms
Source C:\IVAN\MNA\TC5061\semana-05\TC5061-Proyecto-Equipo46\mibici\modeling\train_p3.py
f50bcc3
Logged models
Registered prompts —
Datasets
None
Tags
data_version: d038fe16493d
Buscar
08:48 p. m.
18/10/2026


Pregunta a Gemini
127.0.0.1:5000/#/experiments/423073989401164571/runs/0e94443a5d8a42fb960d70faf45b60e8
Reinicia para actualizar
mlflow 3.6.0
GitHub
Docs
mibici-equipo46 › Runs ›
P3_kmeans_station_usage_profiles
Overview
Model metrics
System metrics
Traces
Artifacts
Parameters (11)
Search parameters
Parameter
Value
baseline KMeans_station_usage_profiles
data_version d038fe16493d
end_month 2026-09
n_clusters 3
profile arrivals_and_departures_by_weekday_and_hour
profile_dimension 336
question P3
random_seed 42
scaler StandardScaler
start_month 2026-01
station_count 470
None
Tags
data_version: d038fe16493d
git_commit: f50bcc3c27cbd616bb48e360198bf7c3... question: P3 team: 46
Registered models
None
Buscar
08:49 p. m.
18/10/2026

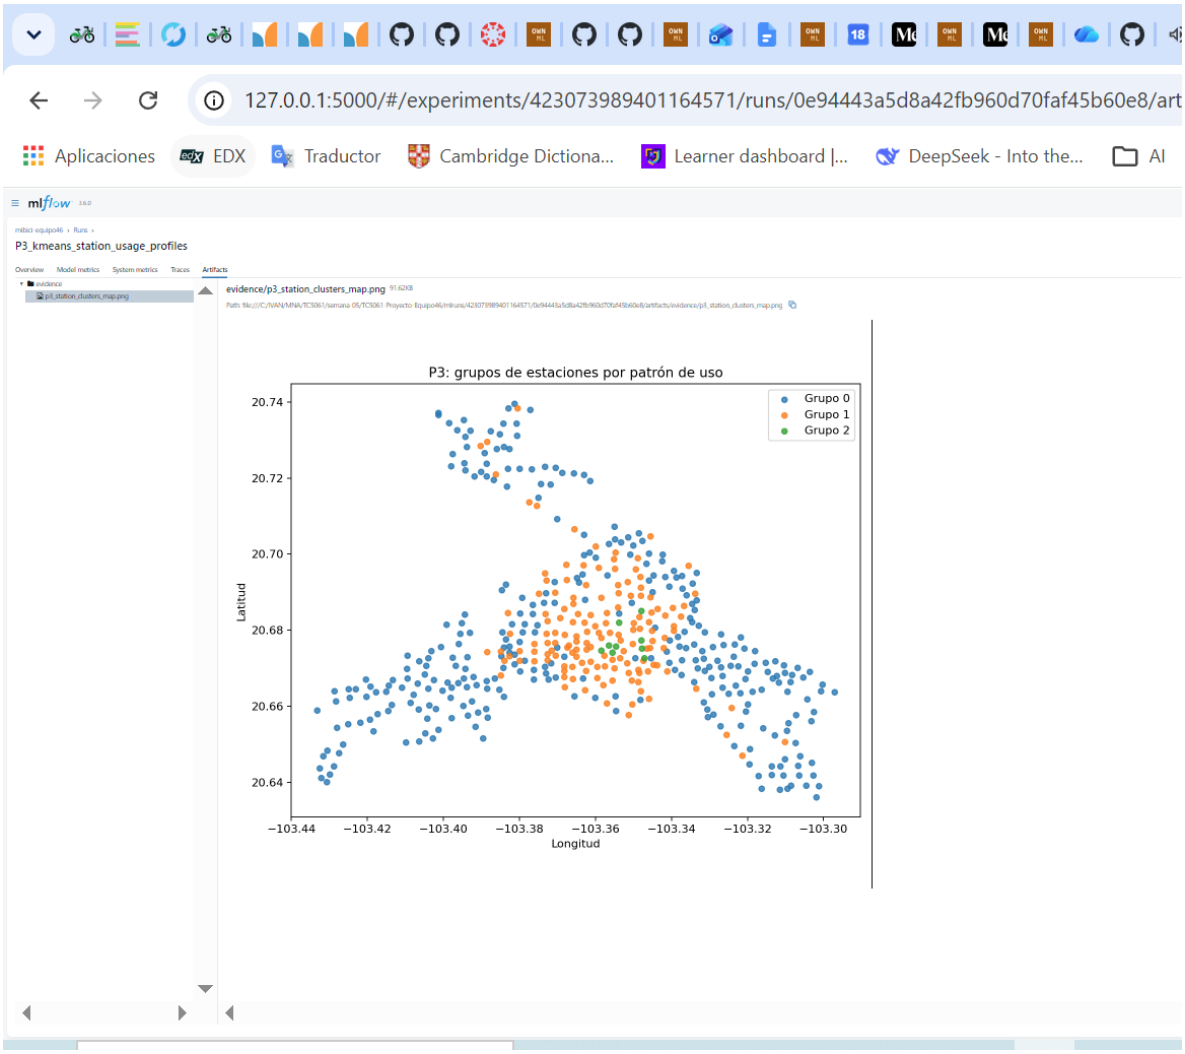
ARTEFACTOS P1:



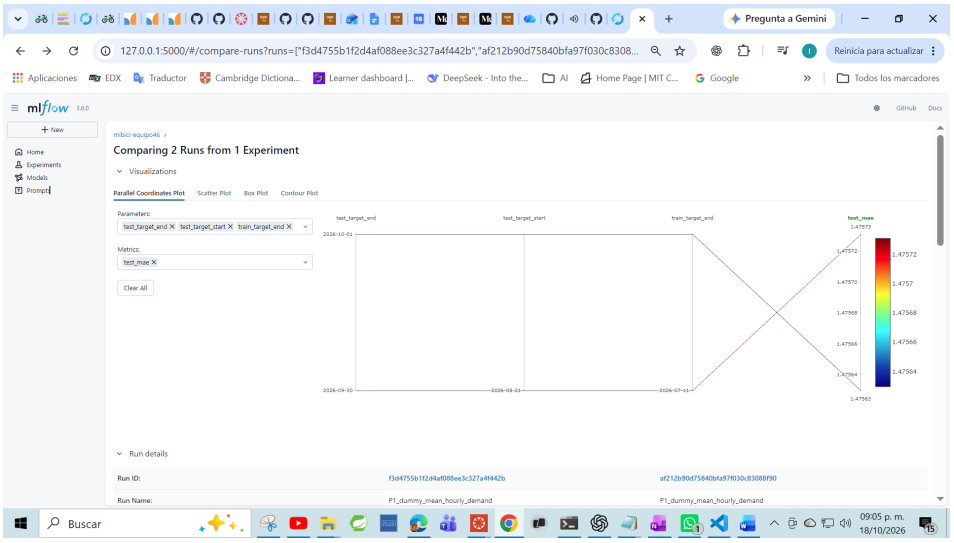
ARTEFACTO P2:

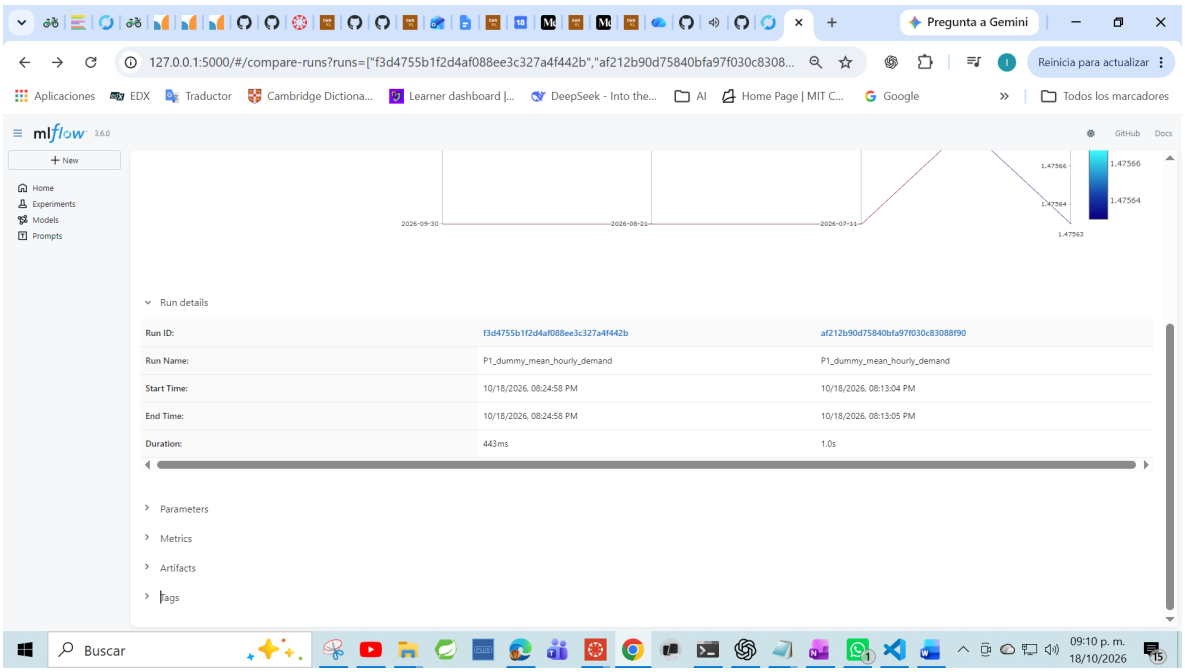


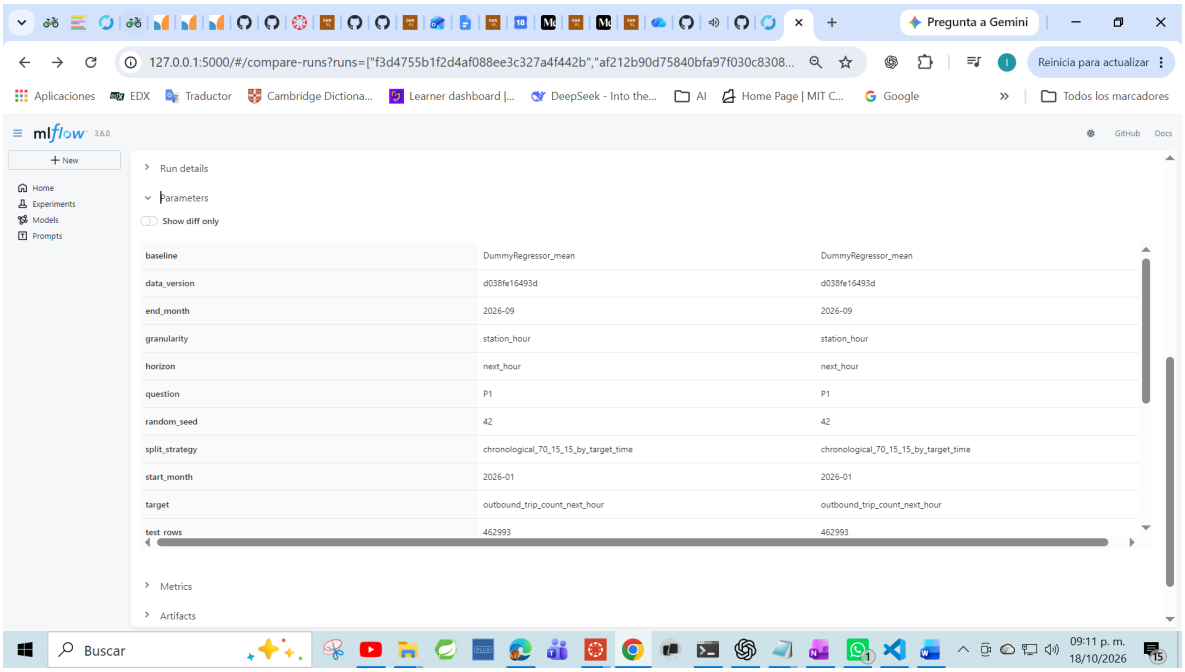
ARTEFACTO P3:

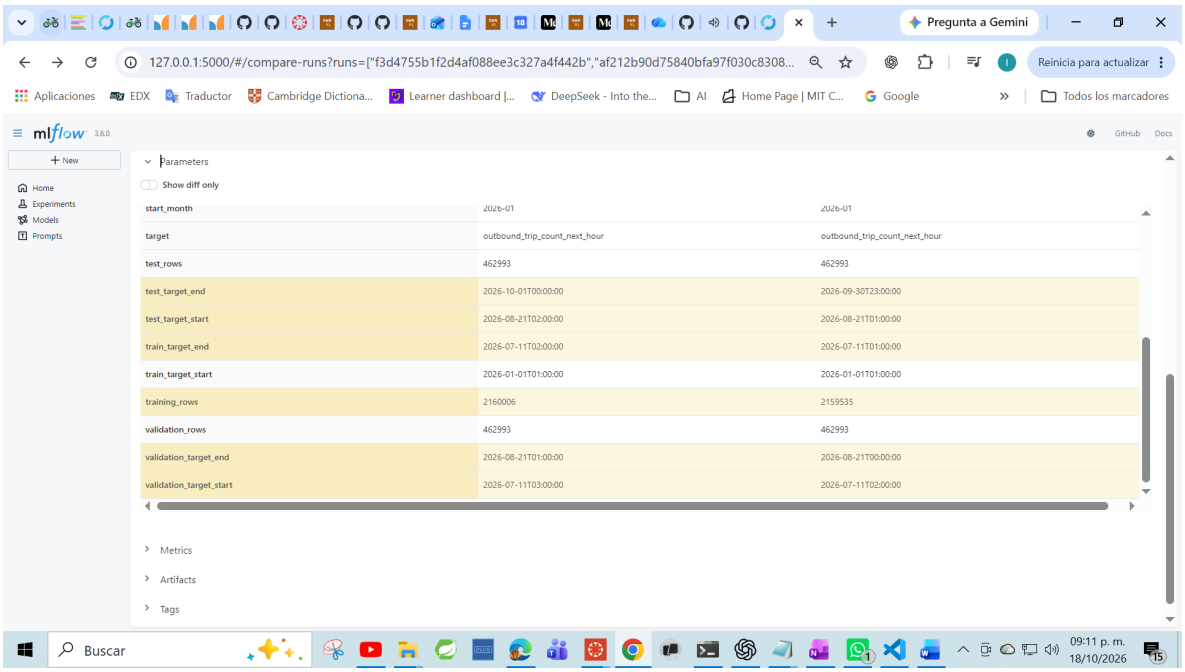


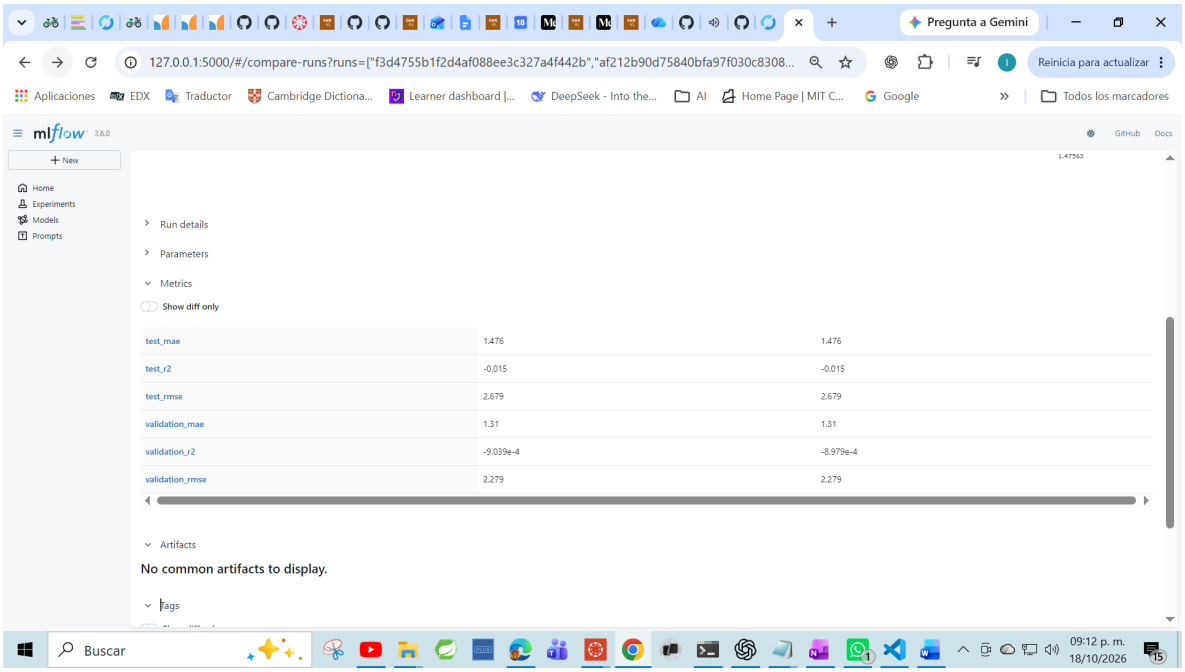
COMPARACION DE DOS RUNS PARA P1:

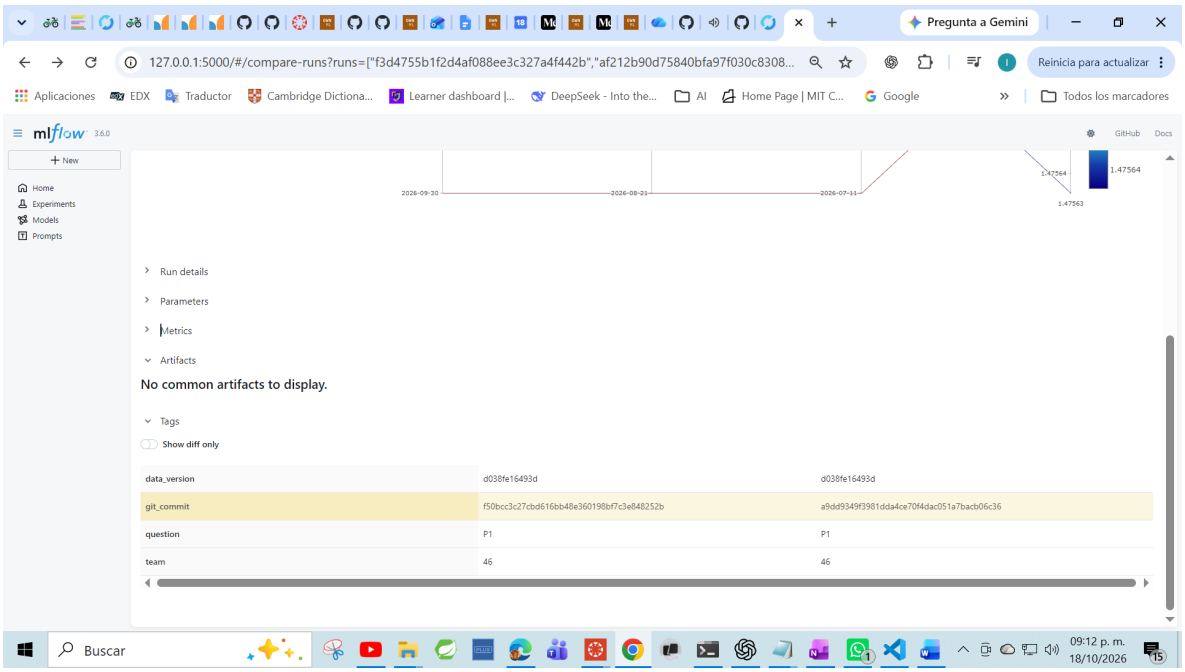



Pregunta a Gemini
127.0.0.1:5000/#/compare-runs?runs=["f3d4755b1f2d4af088ee3c327a4f442b","af212b90d75840bfa97f030c8308...
Reinicia para actualizar
Aplicaciones
EDX
Traductor
Cambridge Dictiona...
Learner dashboard |...
DeepSeek - Into the...
AI
Home Page | MIT C...
Google
Todos los marcadores
mlflow 3.6.0
GitHub
Docs
New
Home
Experiments
Models
Prompts
1.47566
1.47564
1.47563
2026-09-30
2026-08-31
2026-07-31
Run details
Run ID:
f3d4755b1f2d4af088ee3c327a4f442b
af212b90d75840bfa97f030c83088f90
Run Name:
P1_dummy_mean_hourly_demand
P1_dummy_mean_hourly_demand
Start Time:
10/18/2026, 08:24:58 PM
10/18/2026, 08:13:04 PM
End Time:
10/18/2026, 08:24:58 PM
10/18/2026, 08:13:05 PM
Duration:
443ms
1.0s
Parameters
Metrics
Artifacts
Tags
Buscar
09:10 p. m.
18/10/2026


Pregunta a Gemini
127.0.0.1:5000/#/compare-runs?runs=["f3d4755b1f2d4af088ee3c327a4f442b","af212b90d75840bfa97f030c8308...
Reinicia para actualizar
Aplicaciones
EDX
Traductor
Cambridge Dictiona...
Learner dashboard |...
DeepSeek - Into the...
AI
Home Page | MIT C...
Google
Todos los marcadores
mlflow 3.6.0
GitHub
Docs
New
Home
Experiments
Models
Prompts
Run details
Parameters
Show diff only
baseline
DummyRegressor_mean
DummyRegressor_mean
data_version
d038fe16493d
d038fe16493d
end_month
2026-09
2026-09
granularity
station_hour
station_hour
horizon
next_hour
next_hour
question
P1
P1
random_seed
42
42
split_strategy
chronological_70_15_15_by_target_time
chronological_70_15_15_by_target_time
start_month
2026-01
2026-01
target
outbound_trip_count_next_hour
outbound_trip_count_next_hour
test_rows
462993
462993
Metrics
Artifacts
Buscar
09:11 p. m.
18/10/2026


Pregunta a Gemini
127.0.0.1:5000/#/compare-runs?runs=["f3d4755b1f2d4af088ee3c327a4f442b","af212b90d75840bfa97f030c8308...
Reinicia para actualizar
Aplicaciones
EDX
Traductor
Cambridge Dictiona...
Learner dashboard |...
DeepSeek - Into the...
AI
Home Page | MIT C...
Google
Todos los marcadores
mlflow 3.6.0
GitHub
Docs
New
Home
Experiments
Models
Prompts
Parameters
Show diff only
start_month 2026-01 2026-01
target outbound_trip_count_next_hour outbound_trip_count_next_hour
test_rows 462993 462993
test_target_end 2026-10-01T00:00:00 2026-09-30T23:00:00
test_target_start 2026-08-21T02:00:00 2026-08-21T01:00:00
train_target_end 2026-07-11T02:00:00 2026-07-11T01:00:00
train_target_start 2026-01-01T01:00:00 2026-01-01T01:00:00
training_rows 2160006 2159535
validation_rows 462993 462993
validation_target_end 2026-08-21T01:00:00 2026-08-21T00:00:00
validation_target_start 2026-07-11T03:00:00 2026-07-11T02:00:00
Metrics
Artifacts
Tags
Buscar
09:11 p. m.
18/10/2026


Pregunta a Gemini
127.0.0.1:5000/#/compare-runs?runs=["f3d4755b1f2d4af088ee3c327a4f442b","af212b90d75840bfa97f030c8308...
Reinicia para actualizar
Aplicaciones
EDX
Traductor
Cambridge Dictiona...
Learner dashboard |...
DeepSeek - Into the...
AI
Home Page | MIT C...
Google
Todos los marcadores
mlflow 3.6.0
GitHub
Docs
New
Home
Experiments
Models
Prompts
Run details
Parameters
Metrics
Show diff only
test_mae 1.476 1.476
test_r2 -0.015 -0.015
test_rmse 2.679 2.679
validation_mae 1.31 1.31
validation_r2 -9.039e-4 -8.979e-4
validation_rmse 2.279 2.279
Artifacts
No common artifacts to display.
Tags
Buscar
09:12 p. m.
18/10/2026



P1 y P2: función y docstring

features.py · P1 y P2

Función reusable, propósito y control de variables futuras

```python
"""Transformaciones reutilizables para las preguntas P1, P2 y P3 de MiBici."""

from __future__ import annotations

import numpy as np
import pandas as pd


def make_hourly_panel(
    trips: pd.DataFrame,
    stations: pd.DataFrame | None = None,
    risk_fraction: float = 0.10,
) -> pd.DataFrame:
    """Crea variables horarias y objetivos para P1 y P2.

    Cada fila representa una estación y una hora observada. Para P1, el objetivo
    es el número de salidas de esa estación durante la hora siguiente, útil para
    anticipar la demanda local. Para P2, genera un proxy de presión operativa:
    el flujo neto absoluto de la hora siguiente alcanza al menos una fracción
    de la capacidad de la estación.

    Las salidas, llegadas y promedios móviles describen la hora actual y horas
    anteriores. El calendario de la hora objetivo es conocido de antemano.
    Los objetivos se desplazan una hora hacia adelante y no deben incluirse
    entre las variables predictoras. El proxy de P2 no identifica directamente
    estaciones vacías o llenas porque los datos no contienen inventario real.
    """
```

Código fuente del repositorio · numeración de línea original

Variables temporales y objetivos

features.py · variables y objetivos temporales
Variables observadas e indicadores de la siguiente hora

```python
    by_station = panel.groupby("station_id", sort=False)
    panel["departures_this_hour"] = panel["departures"]
    panel["arrivals_this_hour"] = panel["arrivals"]
    panel["departures_mean_last_24h"] = by_station["departures"].transform(
        lambda values: values.rolling(24, min_periods=1).mean()
    )
    panel["departures_mean_last_168h"] = by_station["departures"].transform(
        lambda values: values.rolling(168, min_periods=1).mean()
    )

    target_time = panel["timestamp"] + pd.Timedelta(hours=1)
    panel["target_hour"] = target_time.dt.hour
    panel["target_dayofweek"] = target_time.dt.dayofweek
    panel["target_is_weekend"] = (
        target_time.dt.dayofweek >= 5
    ).astype("int8")
    panel["target_time"] = target_time

    future = panel.groupby("station_id", sort=False)
    panel["target_departures_next_hour"] = future["departures"].shift(-1)
    panel["target_arrivals_next_hour"] = future["arrivals"].shift(-1)

    net_flow = (
        panel["target_departures_next_hour"]
        - panel["target_arrivals_next_hour"]
    )
    panel["target_risk_next_hour"] = (
        (net_flow.abs() >= panel["risk_threshold"])
        .where(net_flow.notna())
        .astype("float32")
    )

    return panel
```

Código fuente del repositorio · numeración de línea original

P3: agregaciones por día y hora

features.py · P3 agregaciones
Conteos por tipo de flujo, día de semana y hora

```python
    profile_columns = pd.MultiIndex.from_product(
        [range(7), range(24)],
        names=["day", "hour"],
    )
    profiles = []

    flows = [
        ("departures", "origin_id", "start_time"),
        ("arrivals", "destination_id", "end_time"),
    ]

    for prefix, station_column, time_column in flows:
        events = data[[station_column, time_column]].copy()
        events["day"] = events[time_column].dt.dayofweek
        events["hour"] = events[time_column].dt.hour

        counts = events.groupby(
            [station_column, "day", "hour"],
            observed=True,
        ).size()

        matrix = counts.unstack(["day", "hour"])
        matrix = matrix.reindex(
            index=station_ids,
            columns=profile_columns,
            fill_value=0,
        ).fillna(0)

        matrix.columns = [
            f"{prefix}_day{day}_hour{hour:02d}"
            for day, hour in matrix.columns
        ]
        profiles.append(matrix.astype("float32"))

    feature_matrix = pd.concat(profiles, axis=1)
    feature_matrix.index.name = "station_id"
    metadata = metadata.set_index("station_id").loc[feature_matrix.index]

    return feature_matrix, metadata.reset_index()
```

Código fuente del repositorio · numeración de línea original

Uso de la función reutilizable en el entrenamiento P3

train_p3.py · uso de feature engineering
Importación del módulo y llamada a build_station_profiles

```
22 from mibici.config import (
23     MANIFEST_PATH,
24     MLFLOW_EXPERIMENT_NAME,
25     PROCESSED_DATA_DIR,
26     PROJ_ROOT,
27     RANDOM_SEED,
28 )
29 from mibici.features import build_station_profiles
30
```

```
90     mlflow.set_tracking_uri(tracking_uri)
91     mlflow.set_experiment(MLFLOW_EXPERIMENT_NAME)
92
93     trips, stations, manifest = load_inputs()
94     profiles, metadata = build_station_profiles(trips, stations)
95
96     if len(profiles) <= N_CLUSTERS:
```

Código fuente del repositorio · numeración de línea original

9. Gobernanza, privacidad y límites del estudio

- Los archivos abiertos no equivalen a una autorización ilimitada de redistribución: la licencia específica de la descarga no fue identificada en las páginas públicas examinadas. Se mantiene atribución y revisión de condiciones publicadas.
- La ingesta retira user_id; los baselines propuestos omiten género y año de nacimiento. Los gráficos se limitan a agregados por estación/horario; no se publican trayectorias individuales.
- P2 mide riesgo aproximado por flujos, nunca falta real de bicicletas/anclajes. Validar esa interpretación exigiría inventarios temporales o registros operativos externos.
- Los datos de nueve meses no cubren un año completo. Los hallazgos no pueden generalizarse automáticamente a todas las estaciones o temporadas.
- Para no confundir disponibilidad operativa y ausencia de datos, se registran horas sin viajes y se distinguen estaciones inactivas, retiradas y sin capacidad válida.
- Toda decisión de rebalanceo o expansión debe evaluarse con personal operativo y restricciones logísticas; el modelo es una herramienta de apoyo.

10. Conclusiones

La propuesta plantea una plataforma metodológica común con tres aplicaciones diferentes: pronosticar demanda, identificar presión futura aproximada sobre estaciones y describir tipologías de uso. Su calidad depende de separar predictores disponibles al momento de la decisión y resultados observados posteriormente, documentar límites del catálogo y evitar atribuir a los viajes una medición directa del inventario. Baselines sencillos, corte temporal, manifiestos de datos y MLflow permitirán evaluar objetivamente futuras mejoras (Huyen, 2022; Wilson, 2022).

Como evidencia documental, se integró el Canvas OWNML oficial v1.2 sin alterar sus atribuciones originales y se alinearon las decisiones de sus diez bloques con el alcance de P1, P2 y P3. El repositorio conserva una base inicial de ingesta según el material recibido, pero la reproducibilidad integral todavía debe demostrarse mediante clon limpio, implementación de features y runs reales con capturas. Esta distinción entre formulación, ejecución y evidencia evita presentar resultados aún no verificados como si fueran resultados terminados.

Referencias (APA 7)

- Cookiecutter Data Science. (s. f.). Cookiecutter Data Science. https://cookiecutter-data-science.drivendata.org/
- Dorard, L. (2015). Machine Learning Canvas (versión 1.2) [Plantilla de planificación, licencia CC BY-SA 4.0]. OWNML. https://www.ownml.co/machine-learning-canvas
- Huyen, C. (2022). Designing machine learning systems: An iterative process for production-ready applications. O'Reilly Media.
- Lauchande, N. (2021). Machine learning engineering with MLflow. Packt Publishing.
- Mi Bici. (s. f.-a). Datos abiertos. https://mibici.net/es/datos-abiertos/
- Mi Bici. (s. f.-b). Aviso de privacidad. https://mibici.net/es/aviso-de-privacidad/
- MLflow. (s. f.). MLflow Tracking. https://mlflow.org/docs/latest/ml/tracking/
- OWNML. (s. f.). Machine Learning Canvas [Recurso de referencia y descarga]. https://www.ownml.co/machine-learning-canvas
- scikit-learn developers. (s. f.-a). Cross-validation: Evaluating estimator performance. https://scikit-learn.org/stable/modules/cross_validation.html
- scikit-learn developers. (s. f.-b). Metrics and scoring: Quantifying the quality of predictions. https://scikit-learn.org/stable/modules/model_evaluation.html
- Thompson, S. (2023). Managing machine learning projects: From design to deployment. Manning Publications.
- Wilson, B. (2022). Machine learning engineering in action. Manning Publications.
- Equipo 46. (2026). data_manifest.json y README.md [Archivos internos del repositorio TC5061-Proyecto-Equipo46]. GitHub. https://github.com/MonicaRamirez-98/TC5061-Proyecto-Equipo46

Anexo A. Machine Learning Canvas oficial OWNML (versión 1.2), completado para el Proyecto Integrador MiBici – Equipo 46. El archivo Word oficial sigue siendo editable por separado.

MACHINE LEARNING CANVAS

Designed for: Equipo 46 iaOps Designed by: **Axel Rabago** Date: 1/10/2026 Iteration: 1 .

PREDICTION TASK

P1 REGRESIÓN: viajes iniciados por estación en la próxima hora; resultado: conteo ≥ 0.

P2 CLASIFICACIÓN: alerta binaria de presión de flujos en la próxima hora si |salidas − llegadas| / capacidad ≥ 0.25 (umbral provisional). El signo orienta el tipo de riesgo; NO equivale a inventario real.

P3 CLUSTERING: agrupar estaciones por su perfil histórico de uso (sin clase objetivo)

DECISIONS

P1: anticipar la demanda y proponer redistribución preventiva de bicicletas por estación.

P2: ordenar inspecciones; más salidas que llegadas sugiere posible escasez de bicicletas, y el caso inverso, de anclajes. Confirmar con inventario real antes de actuar.

P3: identificar tipos de estaciones para ajustar cobertura y orientar la expansión.

El personal decide; el modelo solo

VALUE PROPOSITION

USUARIOS: operación y rebalanceo de MiBici (P1 y P2); planeación del sistema y urbana (P3).

NECESIDAD: la demanda cambia por estación, horario y día; los flujos de entrada y salida pueden desbalancearse; las estaciones tienen perfiles distintos.

BENEFICIO: anticipar viajes, focalizar verificaciones y reconocer grupos comparables para distribuir mejor la flota y fundamentar decisiones de cobertura.

INTEGRACIÓN PROPUESTA: reporte horario, tabla de alertas y mapa de clústeres para revisión humana.

ALCANCE: prototipo analítico académico, no despliegue productivo ni medición directa de bicicletas disponibles.

DATA COLLECTION

mibici/dataset.py

descarga automáticamente los CSV mensuales (ene–sep 2026) y el catálogo de estaciones (sep 2026); normaliza esquemas, codificación y fechas; genera Parquet.

Un manifiesto documenta conteos, SHA-256 y versión lógica d038fe16493d.

ACTUALIZACIÓN PROPUESTA: incorporar nuevos meses, validar cambios de esquema, generar nuevos

DATA SOURCES

FUENTE ABIERTA:

mibici.net/es/datos-abiertos/

datos_abiertos_AAAA_MM.csv (viajes, tiempos, origen y destino).

ESTACIONES: nomenclatura_2026_09.csv (identificador, coordenadas y capacidad).

SEGÚN MANIFIESTO DEL EQUIPO: 9

IMPACT SIMULATION

SIMULACIÓN: validación en julio y prueba en ago–sep 2026, sin intervenciones reales.

P1: errores MAE/RMSE y mejora frente a naive semanal; revisar subestimaciones de alta demanda.

P2: costo relativo preliminar de falso negativo = 3 y falso positivo = 1 (hipótesis, no pesos económicos reales); confirmar alertas con operación.

P3: estabilidad temporal y utilidad de segmentos para planear.

DESPLIEGUE: solo tras superar baselines, validar datos y privacidad, y revisar cobertura y equidad por zona.

MAKING PREDICTIONS

P1/P2: predicciones por LOTES al comienzo de la hora t, con horizonte [t, t+1 h) y datos disponibles antes de t.

P3: grupos recalculados periódicamente (frecuencia mensual propuesta); no predice eventos futuros.

FASE 1: ejecución local por la línea de comandos; sin API ni operación en tiempo real.

BUILDING MODELS

TRES PIPELINES:

P1 naive estacional vs Random Forest/gradient boosting para regresión;

P2 Dummy/regla vs Random Forest de clasificación; **P3** K-Means inicial vs k ajustado.
P1/P2: entrenamiento ene–jun, validación jul y prueba ago–sep 2026; **P3** perfiles construidos con histórico pasado y pruebas de estabilidad.

MLflow registra runs P1/P2/P3, versión de datos, commit, parámetros, métricas y artefactos.

FEATURES

UNIDAD P1/P2: estación × hora, incluyendo horas con cero viajes. **PREDICTORES:** hora, día, fin de semana; conteos previos de salidas/llegadas; medias móviles desplazadas.

P2: balance pasado normalizado por capacidad válida (>0). La presión de la hora futura sirve solo de ETIQUETA, nunca como predictor.

P3: intensidad, perfil horario, picos, uso en fin de semana y balance de flujos históricos; escalar antes de agrupar.

MONITORING

P1: MAE/RMSE; P2: Recall/F1 y alertas falsas; P3: Silhouette/DBI y estabilidad.
MLflow: métricas val/test, versión y commit. Si opera: revisar datos a diario y drift cada mes.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO

Anexo A. Machine Learning Canvas oficial OWNML (versión 1.2), completado para el Proyecto Integrador MiBici – Equipo 46. El archivo Word oficial sigue siendo editable por separado.